

DermAlert: A Data Fabric Architecture for Dermatological Data Integration

Abstract. *This paper presents an experience report on designing and implementing a Data Fabric architecture for integrating multiple heterogeneous dermatological data sources. We address the challenges of data fragmentation in healthcare systems by implementing a semantic integration layer that establishes dynamic equivalence between distinct sources. Our architecture supports data virtualization, and comprehensive governance while enabling a dermatological image collection application and analytical capabilities. We discuss implementation challenges, architectural decisions, and lessons learned during the development process. Results demonstrate improved data accessibility and integration capabilities compared to traditional approaches, highlighting the potential of Data Fabric architectures in healthcare domains.*

Resumo. *Este artigo apresenta um relato de experiência sobre o projeto e a implementação do DermAlert, uma arquitetura Data Fabric para integração de múltiplas fontes heterogêneas de dados dermatológicos. Abordamos os desafios da fragmentação de dados em sistemas de saúde implementando uma camada de integração semântica que estabelece equivalência dinâmica entre fontes distintas. Nossa arquitetura oferece suporte à virtualização de dados e governança abrangente, ao mesmo tempo em que possibilita um aplicativo de coleta de imagens dermatológicas e recursos analíticos. Discutimos os desafios de implementação, as decisões arquitetônicas e as lições aprendidas durante o processo de desenvolvimento. Os resultados demonstram melhor acessibilidade e recursos de integração de dados em comparação com as abordagens tradicionais, destacando o potencial das arquiteturas Data Fabric em domínios da saúde.*

1. Introdução

O Data Fabric é uma arquitetura de dados inteligente que permite integrar, gerenciar e orquestrar dados distribuídos em ambientes diversos. No setor de saúde, essa abordagem facilita a integração segura e padronizada de dados clínicos provenientes de múltiplas fontes, promovendo qualidade, interoperabilidade e governança eficiente.

O câncer de pele é atualmente o tipo mais comum de câncer no mundo. Mais comum em pessoas com mais de 40 anos, o câncer de pele é raro em crianças e negros, com exceção daqueles já portadores de doenças cutâneas. Porém, com a constante exposição de jovens aos raios solares, a média de idade dos pacientes vem diminuindo [10].

Pessoas de pele clara, sensível à ação dos raios solares, com história pessoal ou familiar deste câncer ou com doenças cutâneas prévias são as mais atingidas. De acordo com o Instituto Nacional de Câncer (INCA), a estimativa do câncer não melanoma (Carcinoma Basocelular e Carcinoma Espinocelular) em 2022 foi de 220.490 novos casos, sendo 101.920 homens e 118.570 mulheres, sendo previsto 2.653 mortes para o mesmo ano. Já para o câncer de pele do tipo melanoma, a detecção precoce do câncer é uma estratégia utilizada para encontrar um tumor numa fase inicial e, assim, possibilitar maior chance de tratamento bem-sucedido [11].

A Atenção Primária à Saúde (APS) constitui o primeiro nível de contato dos indivíduos com o sistema de saúde, caracterizada por cuidados abrangentes, acessíveis e coordenados. No contexto do câncer de pele, a APS desempenha funções fundamentais: prevenção primária através de educação sobre exposição ultravioleta, prevenção secundária via rastreamento oportunístico, detecção precoce mediante exame clínico da pele, e coordenação do cuidado entre níveis de atenção [12].

Métodos baseados em machine learning têm se mostrado promissores no diagnóstico precoce, especialmente por meio da análise automatizada de imagens dermatológicas. No entanto, viés nos dados de treinamento, como a sub-representação de diferentes tons de pele ou contextos socioeconômicos, compromete a precisão e a equidade desses modelos [13]. Atualmente, os principais repositórios públicos de dados dermatológicos, como o International Skin Imaging Collaboration (ISIC) Archive [22], embora valiosos para pesquisa, apresentam limitações na diversidade de tons de pele representados, sendo predominantemente compostos por imagens de pacientes com tons de pele mais claros [23].

A integração de dados em saúde representa um avanço revolucionário no diagnóstico de câncer de pele, transformando a precisão e acessibilidade dos cuidados dermatológicos. Algoritmos de inteligência artificial alimentados por grandes volumes de dados dermatológicos demonstram superioridade diagnóstica significativa, alcançando 87% de sensibilidade comparado aos 79,8% dos clínicos trabalhando isoladamente. A estruturação e análise sistemática de dados clínicos, imagens dermatológicas e informações epidemiológicas possibilita não apenas diagnósticos mais precisos, mas também a identificação de padrões populacionais, desenvolvimento de modelos preditivos personalizados e democratização do acesso a expertise dermatológica especializada através de sistemas de apoio à decisão baseados em evidências, consolidando os dados como elemento fundamental para enfrentamento efetivo do câncer de pele em escala populacional [13].

Neste estudo, apresentamos o estudo de caso da construção de uma plataforma baseada em Data Fabric para construir base de dados clínica dermatológica mais diversa, segura e padronizada, possibilitando o desenvolvimento de modelos de aprendizado de máquina mais justos e eficazes. Essa abordagem visa melhorar a acurácia do diagnóstico automatizado do câncer de pele em diferentes populações, promovendo avanços tanto tecnológicos quanto éticos na aplicação de IA na saúde.

2. Arquiteturas de Dados e Desafios na Saúde

A digitalização crescente na área da saúde tem impulsionado a adoção de arquiteturas de dados como Data Warehouses e Data Lakes, cada uma com seus benefícios e limitações frente às demandas clínicas. Enquanto os Data Warehouses são eficazes na organização de dados estruturados e históricos, enfrentam dificuldades ao lidar com informações não estruturadas, como imagens médicas ou anotações em prontuários. Por outro lado [5,6], os Data Lakes oferecem maior flexibilidade para a ingestão de dados heterogêneos, mas frequentemente sofrem com desafios relacionados à qualidade, governança e confiabilidade, resultando no conhecido fenômeno dos “pântanos de dados” [7,8,9].

Como resposta a essas limitações, abordagens distribuídas e orientadas a domínios, como o Data Mesh, têm ganhado destaque no cenário internacional. O Data Mesh propõe a descentralização da gestão de dados, tratando-os como produtos sob a responsabilidade das equipes de domínio, o que pode favorecer a escalabilidade e a agilidade organizacional. Contudo, a adoção desse modelo demanda elevado grau de maturidade em governança de dados e infraestrutura tecnológica, aspectos que ainda representam obstáculos importantes para muitas instituições de saúde [2,3,4]. A arquitetura de Data Fabric visa integrar e gerenciar dados distribuídos de forma unificada, sem exigir sua movimentação física. Essa abordagem conecta múltiplas fontes heterogêneas, como bancos relacionais, data lakes e APIs, oferecendo uma camada de abstração que simplifica o acesso e permite análises em ambientes híbridos e multi-nuvem [14].

A governança é garantida por políticas integradas de controle de acesso, auditoria e conformidade, aplicadas de forma consistente em todo o ecossistema de dados. Isso assegura aderência a normas regulatórias como LGPD e GDPR, além de viabilizar o uso ético e seguro dos dados [1]. Ao unir automação, interoperabilidade e governança, o Data Fabric se consolida como uma arquitetura promissora para apoiar aplicações baseadas em inteligência artificial em contextos de alta complexidade, como a saúde.

Diante desse contexto, as arquiteturas de dados em saúde devem atender a requisitos específicos, como a integração de dados estruturados e não estruturados, garantia de segurança e privacidade em conformidade com regulações (LGPD/GDPR), interoperabilidade entre sistemas legados e instituições distintas, além de mecanismos robustos de governança e rastreabilidade [1]. Esses desafios evidenciam a necessidade de soluções mais flexíveis e interoperáveis, contexto em que arquiteturas como o Data Fabric despontam como alternativas promissoras, ao viabilizar a integração padronizada e segura de dados clínicos heterogêneos.

3. Plataforma para gestão de lesões de pele

Nesta pesquisa tivemos o foco no desenvolvimento de uma plataforma que possibilitasse a prevenção de câncer de pele, gestão dos dados regionais e disponibilização de imagens de lesões com diversidade de tons de peles, algo necessário para desenvolvimento de algoritmos de machine learning para a detecção de câncer em peles brasileiras. A plataforma é composta por um aplicativo, focado na atenção primária e responsável pela aquisição qualificada de imagens de lesões de pele, além de metadados do paciente, quanto de um pipeline de dados, e um Data Fabric para gerenciamento dos dados. A visão geral da arquitetura, assim como o fluxo dos dados, está disponível na Figura 1.

Nossa seleção tecnológica foi guiada por cinco critérios fundamentais: escalabilidade, manutenção, operação em conectividade instável, custo-efetividade para o contexto, e flexibilidade para evolução contínua.




Figura 1. Diagrama da Arquitetura para Integração de Dados DermAlert

3.1 Data Fabric

A arquitetura da Data Fabric DermAlert foi planejada para gerenciar e processar grandes volumes de imagens de câncer de pele de maneira eficiente, assegurando segurança, escalabilidade e interoperabilidade. O uso de uma abordagem descentralizada permite que os dados permaneçam em suas fontes originais, ao mesmo tempo em que oferece uma visão unificada e inteligente do ecossistema de dados. Princípios como descentralização, elasticidade, escalabilidade, segurança e governança orientam o projeto, favorecendo a flexibilidade, a expansão dinâmica da infraestrutura e a conformidade com regulamentações de proteção de dados. Recursos de inteligência artificial e automação potencializam tarefas de descoberta e classificação de dados, enquanto requisitos funcionais e não funcionais reforçam a necessidade de armazenamento seguro, processamento eficiente e compartilhamento unificado de informações [15].

A arquitetura centraliza a Data Fabric como núcleo integrador, conectando fontes internas e externas, como hospitais, pesquisadores e sistemas automatizados e utilizando o MinIO para armazenamento distribuído em diferentes camadas. O Apache Airflow orquestra a ingestão e o processamento, enquanto o Delta Lake gerencia metadados e versionamento, e o Spark atua como motor de processamento. O Delta Sharing viabiliza o compartilhamento seguro entre usuários e organizações. O fluxo de dados parte da ingestão e armazenamento inicial, passa pelo processamento e enriquecimento dos dados, e culmina em mecanismos robustos de governança, segurança e colaboração (Figura 2).




Figura 2. Diagrama da Arquitetura do Data Fabric

Os principais componentes incluem pipelines de ingestão, armazenamento distribuído via MinIO, orquestração e processamento com Apache Airflow e Spark, camada de integração e gestão de dados com Data Fabric e Delta Lake, compartilhamento seguro com Delta Sharing, interface de acesso via FastAPI e orquestração de containers com Kubernetes, promovendo escalabilidade e alta disponibilidade.

3.2 Camada de Integração Semântica

A integração semântica funciona como o elemento unificador do nosso Data Fabric, resolvendo um dos maiores desafios em sistemas de saúde: a diversidade terminológica entre diferentes instituições. Implementamos um sistema de equivalências que permite conectar termos distintos que representam o mesmo conceito clínico.

Desenvolvemos também agrupamentos hierárquicos que organizam condições em categorias relacionadas. Quando um pesquisador busca por "Lesões Melanocíticas", o sistema retorna todos os registros das subcategorias, independente da nomenclatura original utilizada em cada instituição. Esta funcionalidade se estende para características morfológicas. Construímos mapeamentos como:

- "Bordas irregulares" = "Margens indefinidas" = "Limites imprecisos"
- "Assimetria presente" = "Forma assimétrica" = "Assimetria grau 2"

Um diferencial fundamental do nosso sistema é a transitividade dos metadados. Isso significa que as equivalências são propagadas automaticamente através da rede de relações. Por exemplo, se o sistema sabe que "melanoma maligno" em um hospital equivale a "melanoma" em outro, e que "melanoma" equivale a "tumor melanocítico maligno" em um terceiro hospital, ele automaticamente estabelece que "melanoma maligno" = "tumor melanocítico maligno", mesmo sem um mapeamento direto. Esta propriedade transitiva elimina a necessidade de definir todas as equivalências possíveis,

tornando o sistema mais eficiente e abrangente à medida que novos dados são incorporados.

A transitividade também funciona entre diferentes níveis hierárquicos. Se uma nova classificação regional é integrada ao sistema, ela é automaticamente relacionada com todas as classificações existentes através das propriedades transitivas, sem necessidade de intervenção manual.

3.3 Virtualização e Federação de Dados

A virtualização e federação de dados permitem o acesso unificado e eficiente a informações distribuídas, sem a necessidade de consolidação física dos dados. O sistema oferece uma camada de virtualização que possibilita consultas em diversas fontes, como sistemas de armazenamento distribuído, bancos de dados relacionais e NoSQL, como se todos os dados estivessem em um único local.

A execução de consultas distribuídas é viabilizada pelo Apache Spark, que atua como motor de processamento em larga escala. O Delta Lake contribui para a eficiência do processamento ao unificar dados em lote e em tempo real. O Spark utiliza processamento em memória e avaliação preguiçosa das operações para otimizar o desempenho, além de distribuir de forma inteligente as tarefas entre os nós do sistema e ajustar a configuração de memória para maximizar a performance.

A abstração da fonte de dados é um dos pilares da arquitetura, permitindo que usuários acessem e analisem dados sem se preocupar com a complexidade da infraestrutura subjacente. O uso de metadados possibilita a conexão e o acesso a dados em diferentes sistemas, mantendo-os em suas infra estruturas originais e evitando a duplicação desnecessária.

3.4 Estrutura de Governança de Dados

O rastreamento da linhagem de dados é fundamental para auditoria, permitindo a compreensão da proveniência e das transformações aplicadas aos dados. O Delta Lake mantém logs transacionais organizando todas as alterações, o que possibilita recuperar versões anteriores para fins de auditoria ou recuperação. Essa abordagem garante rastreabilidade completa, controle de qualidade e versionamento dos dados [16].

O controle de qualidade é aplicado desde a ingestão até o processamento, com métricas específicas para imagens, como resolução, relação sinal-ruído, nitidez e contraste. Os dados passam por validações automáticas, revisões manuais e testes de consistência, assegurando que as imagens atendam aos critérios necessários para análises confiáveis. O sistema também garante integridade e consistência dos dados armazenados, com foco constante em segurança e privacidade.

A camada de metadados é a espinha dorsal da governança, mantendo um catálogo abrangente e utilizando IA e aprendizado de máquina para automatizar a descoberta, classificação e enriquecimento de informações. O controle de acesso baseado em papéis garante que políticas de segurança e conformidade sejam aplicadas

de maneira consistente em todo o ambiente. Desde o início do projeto, a conformidade com regulamentações de proteção de dados é priorizada, com a adoção de medidas como criptografia, controle de acesso e anonimização de dados para salvaguardar informações sensíveis.

4. Pipeline de Processamento de Dados

4.1 Orquestração de Pipeline

O DermAlert implementa um sistema eficiente de orquestração de dados utilizando o Apache Airflow para gerenciar o fluxo de informações dermatológicas por meio de DAGs. Desenvolvemos DAGs especializados que automatizam a coleta de dados de diversas fontes institucionais, como dados governamentais, fontes públicas e centros de saúde, seguindo fluxos de trabalho clinicamente relevantes.

A implementação principal consiste em pipelines que extraem imagens dermatológicas e seus metadados associados. Após a extração, os dados passam por um processo inicial de validação antes de serem direcionados para o armazenamento apropriado: as imagens são armazenadas na camada bronze do MinIO (nosso sistema de armazenamento de objetos distribuídos), enquanto os metadados correspondentes são estruturados e armazenados no Delta Lake.

Para o tratamento de erros, implementamos estratégias de recuperação com base na natureza das falhas. Erros transitórios são gerenciados por meio de políticas de repetições configuráveis.

4.2 Padrões de Transformação de Dados

A padronização de dados é fundamental para nossa arquitetura devido à heterogeneidade das fontes de dermatologia. Implementamos transformações que normalizam formatos de imagem e terminologias clínicas associadas. Isso inclui a conversão para formatos padronizados, a normalização de metadados e o mapeamento para terminologias comuns de dermatologia, facilitando a interoperabilidade semântica.

O backend principal do Data Fabric executa tarefas assíncronas agendadas que consultam regularmente as fontes de dados, buscando novos registros e atualizações. Essas tarefas são responsáveis por integrar os novos dados ao catálogo unificado, estabelecer relações semânticas e enriquecer os metadados associados. Essa abordagem permite que o sistema mantenha uma visão consistente e atualizada dos dados, mesmo quando as fontes são atualizadas em momentos diferentes.

5. Aplicativo de Coleta DermAlert

Desenvolvemos o aplicativo DermAlert para uso em posto de saúde: detecção precoce e monitoramento padronizado de lesões suspeitas de câncer de pele.

O aplicativo serve como ferramenta de apoio durante o atendimento, permitindo que médicos e enfermeiros documentam casos suspeitos diretamente no momento da consulta. O fluxo de trabalho foi desenvolvido após as consultas dermatológicas.

Quando um paciente apresenta sintomas suspeitos, o profissional inicia o cadastro no aplicativo seguindo um fluxo intuitivo:

- Cadastro básico do paciente (nome ou identificador)
- Anamnese simplificada com foco em fatores de risco (histórico familiar, exposição solar)
- Documentação fotográfica da lesão com guias de enquadramento
- Marcação da região anatômica
- Caracterização da lesão por meio de um formulário estruturado (tamanho, cor, bordas)

Adição de anotações clínicas relevantes. Um aspecto importante foi a implementação de um sistema integrado de consentimento digital, que explica ao paciente como seus dados serão utilizados para pesquisa e aprimoramento do sistema. O aplicativo é uma das fontes de dados conectadas ao Data Fabric.

5.2 Integração Técnica

A integração técnica foi desenvolvida considerando os desafios específicos do contexto brasileiro de saúde pública.

- Anonimização parcial dos dados antes da sincronização com data fabric
- Segregação de identificadores pessoais e dados clínicos

Também desenvolvemos e planejamos integração com APIs governamentais em preparação para futuras validações. O sistema está estruturado para receber resultados de biópsia através do sistema SISCAN, permitindo-nos comparar diagnósticos algorítmicos com confirmações histopatológicas. Esse feedback será crucial para refinar continuamente os modelos de aprendizado de máquina e avaliar sua eficácia em diferentes cenários clínicos.

A arquitetura técnica foi projetada com foco na escalabilidade. Começamos com uma instalação piloto em 5 unidades, mas o sistema está dimensionado para suportar até 100% de uso simultâneo, sem alterações significativas na infraestrutura.

6. Discussões e Lições Aprendidas

O desenvolvimento da arquitetura DermAlert proporcionou uma compreensão aprofundada dos desafios e benefícios associados à aplicação do paradigma de Data Fabric em contextos de saúde. Uma das principais lições aprendidas foi o impacto positivo da integração de fontes externas de dados, como repositórios públicos, centros de saúde e bases de pesquisa, na qualidade e diversidade dos dados coletados. Essa diversidade mostrou-se essencial para reduzir vieses em modelos de aprendizado de

máquina, especialmente no diagnóstico de câncer de pele em diferentes tonalidades de pele, contexto relevante para a população brasileira.

Optar por uma arquitetura de Data Fabric em vez de um Data Lake tradicional permitiu não apenas a centralização lógica dos dados, mas também uma governança mais robusta, com rastreabilidade, controle de versionamento (via Delta Lake) e compartilhamento seguro (com Delta Sharing). A abstração das fontes por meio da virtualização e a federação de dados demonstraram-se eficazes para evitar silos, possibilitando o consumo self-service das informações sem a necessidade de migração física. Outro ponto crítico identificado foi a importância da automação. O uso do Apache Airflow como orquestrador tornou possível o gerenciamento de ingestões e transformações de dados de forma escalável, liberando as equipes técnicas de tarefas repetitivas e contribuindo para maior eficiência operacional. Adicionalmente, a criação de datasets lógicos, que consistem em coleções dinâmicas de referências e metadados, viabilizou análises sob demanda com materialização seletiva de imagens, reduzindo significativamente os custos de armazenamento e o tempo de preparação de dados.

Por fim, a conformidade com normas como a LGPD foi tratada como diferencial estratégico desde o início, e não como mera exigência legal. A adoção de medidas como anonimização, criptografia e controle de acesso baseado em papéis foi decisiva para garantir segurança e transparência no uso de dados sensíveis. Concluímos que a adoção de uma arquitetura Data Fabric, aliada a tecnologias de código aberto e práticas sólidas de governança, oferece um caminho viável e escalável para aplicações em saúde pública, especialmente em cenários com restrições de infraestrutura.

O software livre, um movimento impulsionado pelo compartilhamento do conhecimento tecnológico e pela liberdade dos usuários, oferece uma gama substancial de benefícios que vão além da mera redução de custos. Do ponto de vista técnico e de desenvolvimento, o software livre demonstra altos níveis de confiabilidade e segurança. A abertura do código-fonte permite que milhares de desenvolvedores em todo o mundo possam inspecionar, depurar e sugerir melhorias, resultando em uma rápida detecção e correção de falhas [20]. A adoção de software livre confere a organizações e países independência em relação a fornecedores e monopólios de tecnologia [19]. Isso permite personalizar o software conforme as necessidades locais, sem restrições, e influenciar o desenvolvimento de novas funcionalidades pela participação na comunidade [20]. A liberação do código-fonte incita empresas a inovar e focar em modelos de negócio baseados em serviços, como suporte, em vez de licenças restritivas. A interoperabilidade é reforçada por padrões e protocolos abertos, que deveriam ser bens públicos para a sociedade em rede. Experiências em diferentes regiões, demonstram a viabilidade e os benefícios de políticas públicas que incentivam o software livre, tornando-o uma opção socialmente justa, economicamente viável e tecnologicamente sustentável [19].

7. Trabalhos relacionados

O estudo de DHAYNE et al. (2019) destaca os desafios de integrar dados médicos heterogêneos, como imagens, informações genômicas e EHRs. Soluções como data lakes, data warehouses modernas, Hadoop e Apache Hive são apontadas para

armazenamento e análise eficiente desses dados. O uso de web semântica (ontologias como SNOMED CT e UMLS) e aprendizado de máquina melhora a interoperabilidade e a análise de imagens, auxiliando na detecção precoce de doenças e na personalização de tratamentos. O iManageCancer é citado como exemplo prático dessas integrações.

Já o artigo de XU et al. (2019) discute a integração da análise de dados em clínicas sob o conceito de "Connected Health", buscando otimizar decisões e manejo de doenças. Salienta a importância da "Translational Medicine" e da combinação de abordagens quantitativas e qualitativas para interpretar prontuários eletrônicos e narrativas de pacientes, especialmente em câncer. Apesar dos avanços, desafios como interoperabilidade e privacidade persistem, sendo que padrões como HL7 e iniciativas como BD2K são essenciais para a integração e uso eficiente de big data biomédico.

8. Conclusão

O uso de dados de saúde em aplicações de machine learning apresenta desafios significativos relacionados à fragmentação das fontes, heterogeneidade semântica, vies nos dados e requisitos rigorosos de segurança e privacidade. No contexto do diagnóstico dermatológico, essas limitações afetam diretamente a eficácia dos modelos preditivos, sobretudo em populações sub-representadas. A coleta e integração sistemática de dados clínicos e imagens de lesões, respeitando princípios de governança e diversidade, torna-se essencial para o desenvolvimento de algoritmos mais justos, confiáveis e clinicamente relevantes. Assim, este trabalho parte do desafio de construir uma infraestrutura capaz de orquestrar esses dados de forma ética e interoperável, viabilizando avanços em inteligência artificial aplicada à saúde pública.

O desenvolvimento da plataforma DermAlert representa um avanço significativo na aplicação de arquitetura Data Fabric para o contexto dermatológico brasileiro, pois combina uma arquitetura resiliente e adaptável às condições de infraestrutura desafiadoras do sistema de saúde, uma camada de integração semântica que resolve a heterogeneidade terminológica entre instituições e uma demonstração prática de como tecnologias open-source podem ser ajustadas para criar soluções especializadas de baixo custo voltadas à saúde pública. Além de disponibilizar a infraestrutura, a plataforma possui um aplicativo para a aquisição de imagens de lesões de pele e metadados da lesão do paciente. Essa nova base de dados, respeitando os padrões internacionais e disponibilizada no Data Fabric, contribui com a comunidade científica com uma diversidade de tons de pele, possibilitando o treinamento de modelos de machine learning mais adaptados para a realidade da população brasileira.

Trabalhos futuros incluem expansão para outras subespecialidades dermatológicas além de lesões oncológicas, como dermatoses inflamatórias e infecciosas. Estamos desenvolvendo capacidade de análise longitudinal para acompanhamento automático de evolução de lesões ao longo do tempo e integrando modelos de risco personalizado baseados em fatores genéticos e ambientais.

Uma oportunidade particularmente promissora é a implementação de federação de aprendizado, permitindo que modelos sejam treinados em dados distribuídos sem necessidade de centralização, endereçando importantes preocupações de privacidade.

9. Referencias

1. BENFELDT, O.; PERSSON, J. S.; MADSEN, S. Data governance as a collective action problem. *Information Systems Frontiers*, p. 299–313, 2020.
2. DEGHANI, Z. Data Mesh: Delivering Data-Driven Value at Scale. [S.l.: s.n.], 2020.
3. MARTINEZ, L. Federated governance in data mesh implementations. *International Journal of Data Management*, v. 15, p. 56–78, 2022.
4. AKHTAR, R. Decentralized data mesh architectures: Benefits and challenges. *Journal of Data Science*, p. 123–145, 2021.
5. SANTOSO, L. W.; YULIA. Data warehouse with big data technology for higher education. In: *Proceedings of the 4th Information Systems International Conference (ISICO 2017)*. [S.l.: s.n.], 2017.
6. NAMBIAR, A.; MUNDRA, D. An overview of data warehouse and data lake in modern enterprise data management. *Big Data and Cognitive Computing*, p. 132, 2022.
7. ZAGAN, E.; DANUBIANU, M. Data lake approaches: A survey. p. 189–191, 2020.
8. NUTHALAPATI, A. Architecting data lake-houses in the cloud: Best practices and future direction. [S.l.: s.n.], 2018. 1903 p.
9. FANG, T. Data Lakes: Foundations and Innovations. [S.l.: s.n.], 2021.
10. INSTITUTO NACIONAL DE CÂNCER (INCA), 2022. Tipos de Câncer: Câncer de Pele Melanoma [online]. Rio de Janeiro: INCA. Disponível em: <https://www.gov.br/inca/pt-br/assuntos/cancer/tipos/pele-melanoma/profissional-de-saude>. [Acesso em 24 junho 2024].
11. INSTITUTO NACIONAL DE CÂNCER (INCA), 2023. *Tipos de Câncer: Câncer de Pele Não Melanoma* [online]. Rio de Janeiro: INCA. Disponível em: <https://www.gov.br/inca/pt-br/assuntos/cancer/tipos/pele-nao-melanoma>. [Acesso em 24 junho 2024].
12. Jones, O.T., Ranmuthu, C.K.I., Hall, P.N., Funston, G., Walter, F.M. (2020). Recognising Skin Cancer in Primary Care. *Advances in Therapy*, 37(1), 603-616.
13. SALINAS, M. P. et al. A systematic review and meta-analysis of artificial intelligence versus clinicians for skin cancer diagnosis. *npj Digital Medicine*, v. 7, p. 125, 2024.
14. Gartner. What is Data Fabric? Uses, Definition & Trends. 2024. Disponível em: <https://www.gartner.com/en/data-analytics/topics/data-fabric>. [Acesso em 21 junho 2025].
15. SHARMA, V. et al. (Ed.). *Data Fabric Architectures: Web-Driven Applications*. [S.l.]: De Gruyter, 2023.

16. LEE, D. et al. Delta Lake: The Definitive Guide: Modern Data Lakehouse Architectures with Data Lakes. [S.l.]: O'Reilly Media, 2024.
17. DHAYNE, H. et al. In search of big medical data integration solutions - a comprehensive survey. IEEE Access, 2019.
18. XU, L. et al. What clinics are expecting from data scientists? a review on data oriented studies through qualitative and quantitative approaches. IEEE Access, 2019.
19. SILVEIRA, S. A. Software livre: a luta pela liberdade do conhecimento. 1. ed. São Paulo: Editora Fundação Perseu Abramo, 2004. ISBN 85-7643-003-7.
20. ALMARZOUQ, Mohammad; ZHENG, Li; RONG, Guang; GROVER, Varun. Open Source: Concepts, Benefits, and Challenges. Communications of the Association for Information Systems, v. 16, n. 1, p. 756–784, nov. 2005.
21. BONACCORSI, Andrea; ROSSI, Cristina. Why Open Source software can succeed. Research Policy, v. 32, n. 7, p. 1243–1258, jul. 2003.
22. International Skin Imaging Collaboration. SIIM-ISIC 2020 challenge dataset. International Skin Imaging Collaboration; 2020. Available from: <https://doi.org/10.34970/2020-ds01>
23. DANESHJOU, R. et al. Disparities in dermatology AI performance on a diverse, curated clinical image set. Science Advances, v. 8, n. 32, p. abq 6147, 2022.