

Universidade de Brasília – UnB
Faculdade UnB Gama – FGA
Nome do Curso

Título: Subtítulo do Trabalho

Autor: Nome do Autor
Orientador: Titulação Acadêmica e Nome do Orientador

Brasília, DF
2013



Nome do Autor

Título: Subtítulo do Trabalho

Monografia submetida ao curso de graduação
em Nome do Curso da Universidade de Bra-
sília, como requisito parcial para obtenção do
Título de Bacharel em Nome do Curso.

Universidade de Brasília – UnB

Faculdade UnB Gama – FGA

Orientador: Titulação Acadêmica e Nome do Orientador

Coorientador: quando houver, Titulação Acadêmica e Nome do
Orientador

Brasília, DF

2013

Nome do Autor

Título: Subtítulo do Trabalho/ Nome do Autor. – Brasília, DF, 2013-
72 p. : il. (algumas color.) ; 30 cm.

Orientador: Titulação Acadêmica e Nome do Orientador

Trabalho de Conclusão de Curso – Universidade de Brasília – UnB
Faculdade UnB Gama – FGA , 2013.

1. Palavra-chave01. 2. Palavra-chave02. I. Titulação Acadêmica e Nome do
Orientador. II. Universidade de Brasília. III. Faculdade UnB Gama. IV. Título:
Subtítulo do Trabalho

CDU 02:141:005.6

Errata

Elemento opcional da ??, 4.2.1.2). **Caso não deseje uma errata, deixar todo este arquivo em branco.** Exemplo:

FERRIGNO, C. R. A. **Tratamento de neoplasias ósseas apendiculares com reimplantação de enxerto ósseo autólogo autoclavado associado ao plasma rico em plaquetas:** estudo crítico na cirurgia de preservação de membro em cães. 2011. 128 f. Tese (Livre-Docência) - Faculdade de Medicina Veterinária e Zootecnia, Universidade de São Paulo, São Paulo, 2011.

Folha	Linha	Onde se lê	Leia-se
1	10	auto-conclavo	autoconclavo

Nome do Autor

Título: Subtítulo do Trabalho

Monografia submetida ao curso de graduação em Nome do Curso da Universidade de Brasília, como requisito parcial para obtenção do Título de Bacharel em Nome do Curso.

Trabalho aprovado. Brasília, DF, 01 de junho de 2013 – Data da aprovação do trabalho:

Titulação Acadêmica e Nome do Orientador
Orientador

Titulação e Nome do Professor Convidado 01
Convidado 1

Titulação e Nome do Professor Convidado 02
Convidado 2

Brasília, DF
2013

A dedicatória é opcional. Caso não deseje uma, deixar todo este arquivo em
branco.

*Este trabalho é dedicado às crianças adultas que,
quando pequenas, sonharam em se tornar cientistas.*

Agradecimentos

A inclusão desta seção de agradecimentos é opcional, portanto, sua inclusão fica a critério do(s) autor(es), que caso deseje(em) fazê-lo deverá(ão) utilizar este espaço, seguindo a formatação de *espaço simples e fonte padrão do texto (sem negritos, aspas ou itálico)*.

Caso não deseje utilizar os agradecimentos, deixar toda este arquivo em branco.

A epígrafe é opcional. Caso não deseje uma, deixe todo este arquivo em
branco.

*“Não vos amoldeis às estruturas deste mundo,
mas transformai-vos pela renovação da mente,
a fim de distinguir qual é a vontade de Deus:
o que é bom, o que Lhe é agradável, o que é perfeito.
(Bíblia Sagrada, Romanos 12, 2)*

Resumo

O resumo deve ressaltar o objetivo, o método, os resultados e as conclusões do documento. A ordem e a extensão destes itens dependem do tipo de resumo (informativo ou indicativo) e do tratamento que cada item recebe no documento original. O resumo deve ser precedido da referência do documento, com exceção do resumo inserido no próprio documento. (...) As palavras-chave devem figurar logo abaixo do resumo, antecidas da expressão Palavras-chave:, separadas entre si por ponto e finalizadas também por ponto. O texto pode conter no mínimo 150 e no máximo 500 palavras, é aconselhável que sejam utilizadas 200 palavras. E não se separa o texto do resumo em parágrafos.

Palavras-chave: latex. abntex. editoração de texto.

Abstract

This is the english abstract.

Key-words: latex. abntex. text editoration.

Lista de ilustrações

Figura 1 – Arquitetura geral de um Data Warehouse	36
Figura 2 – Pipeline de Processamento de Imagens Dermatológicas	61
Figura 3 – Delta Lake: Formato transacional escalável e de uso geral para Lakehouse. (LEE et al.,	

Lista de tabelas

Lista de abreviaturas e siglas

Fig. Area of the i^{th} component

456 Isto é um número

123 Isto é outro número

lauro cesar este é o meu nome

Lista de símbolos

Γ	Letra grega Gama
Λ	Lambda
ζ	Letra grega minúscula zeta
\in	Pertence

Sumário

	Introdução	29
1	REFERENCIAL TEÓRICO	31
1.1		31
1.2	Engenharia de Dados	31
1.2.1	Histórico e Evolução	31
1.2.2	Desafios Atuais	32
1.2.3	Impacto das Dificuldades	33
1.2.4	Práticas de Engenharia de Dados	34
1.3	Data Warehouse	35
1.3.1	Definição e Conceito	35
1.3.2	Arquitetura	36
1.3.3	Quando Utilizar	37
1.3.4	Quando Não Utilizar	38
1.4	Data Fabric	39
1.4.1	Definição e Conceito	39
1.4.2	Arquitetura	40
1.4.3	Quando Utilizar	41
1.4.4	Quando Não Utilizar	42
1.5	Data Lake	43
1.5.1	Tabela Comparativa: Data Lakes vs. Bancos de Dados Tradicionais	44
1.6	Data Mesh: Um Paradigma para Gestão de Dados Descentralizados	44
1.6.1	O que é Data Mesh?	44
1.6.2	Princípios Fundamentais do Data Mesh	44
1.6.3	Vantagens e Desvantagens do Data Mesh	45
1.6.4	Quando Utilizar Data Mesh?	45
1.6.5	Quando Não Utilizar Data Mesh?	45
1.6.6	Ferramentas Open Source para Data Mesh	45
1.6.7	Conclusão	46
1.7	Apache Airflow: Orquestração de Pipelines	46
1.7.1	Conceitos Fundamentais	46
1.7.2	Características Principais	46
1.7.3	Arquitetura	47
1.7.4	Benefícios e Limitações	47
1.7.4.1	Benefícios	47

1.7.4.2	Limitações	47
1.7.5	Melhores Práticas	48
1.8	Kubernetes: Orquestração de Containers para Escalabilidade	48
1.8.1	Arquitetura do Kubernetes	48
1.8.1.1	Control Plane (Master)	48
1.8.1.2	Worker Nodes	48
1.8.2	Conceitos Fundamentais	49
1.8.3	Recursos de Escalabilidade	49
1.8.3.1	Escalabilidade Horizontal	49
1.8.3.2	Alta Disponibilidade	49
1.8.4	Benefícios e Desafios	49
1.8.4.1	Benefícios	49
1.8.4.2	Desafios	50
1.8.5	Melhores Práticas	50
1.9	FastAPI: Desenvolvimento de APIs para Integração de Dados . . .	50
1.9.1	Características Fundamentais	50
1.9.2	Arquitetura e Componentes	51
1.9.2.1	Componentes Principais	51
1.9.3	Integração de Dados com FastAPI	51
1.9.3.1	Modelos de Dados	51
1.9.3.2	Endpoints para Manipulação de Dados	51
1.9.4	Segurança e Autenticação	52
1.9.5	Performance e Escalabilidade	52
1.9.5.1	Métricas de Desempenho	52
1.9.6	Melhores Práticas	52
1.9.7	Limitações e Considerações	53
1.10	Pipelines de Dados no Diagnóstico de Câncer de Pele	53
1.10.1	Arquitetura do Pipeline	53
1.10.2	Componentes Essenciais	54
1.10.2.1	Infraestrutura de Dados	54
1.10.2.2	Modelos de Processamento	54
1.10.3	Fluxo de Dados e Processamento	54
1.10.4	Garantia de Qualidade	55
1.10.5	Desafios e Considerações	55
1.11	Fluxo de Dados em Arquitetura de Data Fabric	56
1.11.1	Componentes do Fluxo de Dados	56
1.11.2	Padrões de Fluxo de Dados	57
1.11.2.1	Fluxo Batch	57
1.11.2.2	Fluxo Real-time	57

1.11.2.3	Fluxo Híbrido	57
1.11.3	Gestão e Controle do Fluxo	57
1.11.4	Integração e Interoperabilidade	58
1.11.5	Desafios e Considerações	59
1.12	Ingestão de Dados e Preprocessamento de Imagens	59
1.12.1	Ingestão de Dados	59
1.12.1.1	Fontes de Dados	59
1.12.2	Preprocessamento de Imagens	60
1.12.3	Pipeline de Processamento	60
1.12.3.1	Etapas do Pipeline	61
1.12.4	Técnicas de Augmentação de Dados	61
1.12.5	Controle de Qualidade	62
1.13	MinIO Object Storage	62
1.13.1	Arquitetura e Benefícios	62
1.13.2	Relevância no Cenário Atual de Armazenamento em Nuvem	63
1.14	Delta Lake	63
1.14.1	Arquitetura e Benefícios	63
1.14.2	Relevância no Cenário Atual de Big Data	64
2	RELATED WORKS	67
2.1	In Search of Big Medical Data Integration Solutions - A Comprehensive Survey	67
2.2	What Clinics Are Expecting From Data Scientists? A Review on Data Oriented St	67
	REFERÊNCIAS	69

Introdução

Este documento apresenta considerações gerais e preliminares relacionadas à redação de relatórios de Projeto de Graduação da Faculdade UnB Gama (FGA). São abordados os diferentes aspectos sobre a estrutura do trabalho, uso de programas de auxílio a edição, tiragem de cópias, encadernação, etc.

Este template é uma adaptação do ABN \TeX 2¹.

¹ <<https://github.com/abntex/abntex2/>>

1 Referencial Teórico

1.1

Estas instruções apresentam um conjunto mínimo de exigências necessárias a uniformidade de apresentação do relatório de Trabalho de Conclusão de Curso da FGA. Estilo, concisão e clareza ficam inteiramente sob a responsabilidade do(s) aluno(s) autor(es) do relatório.

As disciplinas de Trabalho de Conclusão de Curso (TCC) 01 e Trabalho de Conclusão de Curso (TCC) 02 se desenvolvem de acordo com Regulamento próprio aprovado pelo Colegiado da FGA. Os alunos matriculados nessas disciplinas devem estar plenamente cientes de tal Regulamento.

1.2 Engenharia de Dados

A era da informação, impulsionada pela digitalização crescente, nos coloca diante de uma explosão de dados sem precedentes. Nesse cenário, a Engenharia de Dados emerge como uma área essencial para transformar essa massa de dados brutos em informação valiosa e conhecimento estratégico. A Engenharia de Dados, utilizando princípios de engenharia e ciência da computação, projeta, constrói e gerencia sistemas robustos de dados, abrangendo desde a coleta e armazenamento até o processamento, a análise e a visualização.

A importância da Engenharia de Dados reside na sua capacidade de extrair valor dos dados. Através da conversão de dados brutos em insights acionáveis, as organizações podem otimizar suas operações, identificar tendências de mercado, personalizar a experiência do cliente e tomar decisões estratégicas mais eficazes. Essa capacidade é crucial no contexto do Big Data, com seus desafios de volume, velocidade, variedade e veracidade.

Garantir a qualidade dos dados é um fator crítico. Decisões baseadas em dados imprecisos ou inconsistentes podem acarretar resultados indesejáveis, ineficiência operacional e perda de oportunidades (REDMAN, 1998). A Engenharia de Dados busca assegurar a qualidade dos dados por meio de processos de limpeza, transformação e validação, garantindo que os dados sejam confiáveis e adequados para análise (HAUG; ZACHARIASSEN; LIEMPD, 2011).

1.2.1 Histórico e Evolução

Embora tenha ganhado destaque recentemente, a Engenharia de Dados tem suas raízes em áreas como gerenciamento de banco de dados e processamento de dados. O conceito de dados como ativo surgiu em 1994 com o Hawley Committee, que definiu ativos de dados como "Dados que são ou devem ser documentados e que têm valor ou valor potencial". Essa visão impulsionou a importância da governança de dados dentro das organizações (ALHASSAN; SAMMON; DALY, 2016). Essa necessidade já apontava para a importância de tratar os dados como um ativo valioso e gerenciá-los adequadamente.

Com o avanço da tecnologia e o surgimento de novas fontes de dados, como mídias sociais, dispositivos IoT e streaming de dados, essa área evoluiu para abranger um espectro mais amplo de tecnologias e práticas. A necessidade de lidar com o Big Data impulsionou o desenvolvimento de novas arquiteturas, como o Hadoop e o Spark, e de bancos de dados NoSQL, capazes de lidar com grandes volumes e diferentes formatos de dados (VOLK et al., 2019). A ascensão da computação em nuvem também desempenhou um papel fundamental na evolução da Engenharia de Dados, fornecendo infraestrutura escalável e flexível para armazenamento e processamento de dados (KATAL; WAZID; GOUDAR, 2013). Além disso, a integração com o aprendizado de máquina tem se tornado cada vez mais importante, permitindo a aplicação de algoritmos de aprendizado para análise preditiva, detecção de anomalias e outras tarefas complexas (L'HEUREUX et al., 2017).

1.2.2 Desafios Atuais

A Engenharia de Dados enfrenta desafios complexos e multifacetados, impulsionados pela natureza dinâmica dos dados modernos. Entre os principais desafios, destaca-se a questão da escalabilidade. A necessidade de processar volumes crescentes de dados, provenientes de diversas fontes, exige sistemas e infraestruturas altamente escaláveis. As arquiteturas tradicionais de banco de dados frequentemente se mostram inadequadas para lidar com a escala do Big Data, demandando a adoção de novas tecnologias e abordagens (KATAL; WAZID; GOUDAR, 2013).

Outro desafio relevante é a variedade de dados. A heterogeneidade dos dados, que pode incluir informações estruturadas, semi-estruturadas e não estruturadas, representa um obstáculo significativo para a integração e o processamento. A Engenharia de Dados deve lidar com diferentes formatos, como texto, imagens, áudio e vídeo, além de dados de sensores, logs de eventos e mídias sociais (VOLK et al., 2019). Essa necessidade de integrar e analisar dados de origens e formatos diversos exige o uso de ferramentas e técnicas especializadas, como ETL e processamento de linguagem natural.

A velocidade dos dados é também um aspecto desafiador. O processamento em tempo real, como o streaming de dados, impõe a necessidade de arquiteturas e tecnologias

adequadas para lidar com o fluxo constante de informações. A Engenharia de Dados deve se adaptar a essa realidade, desenvolvendo soluções capazes de capturar, processar e analisar dados em tempo real, garantindo a eficiência e a agilidade necessárias para responder às demandas modernas (L'HEUREUX et al., 2017).

A qualidade dos dados é um ponto crítico no contexto da Engenharia de Dados. Garantir a precisão, consistência e confiabilidade das informações é essencial, especialmente no ambiente de Big Data, onde a complexidade e a variedade de dados podem amplificar os problemas relacionados à qualidade. Conforme destacado por Redman (1998), a baixa qualidade dos dados pode resultar em insatisfação dos clientes, aumento de custos, tomada de decisões ineficazes e redução da capacidade de desenvolver e implementar estratégias. Em casos extremos, os custos associados à baixa qualidade dos dados podem representar entre 8% e 12% da receita de uma empresa, além de atingir até 40% a 60% das despesas em organizações de serviços (REDMAN, 1998).

Por fim, a segurança e a privacidade dos dados são aspectos indispensáveis. A proteção de informações sensíveis e a conformidade com regulamentações, como a GDPR e a LGPD, requerem medidas de segurança abrangentes. Isso inclui a adoção de práticas como criptografia, controle de acesso e anonimização, que são fundamentais para garantir a proteção dos dados e a privacidade dos usuários, atendendo às exigências legais e éticas.

1.2.3 Impacto das Dificuldades

As dificuldades enfrentadas na Engenharia de Dados podem ter um impacto significativo nas organizações, afetando diversos aspectos críticos. Uma das consequências mais evidentes é a tomada de decisão ineficaz. Decisões baseadas em dados imprecisos, inconsistentes ou incompletos podem gerar resultados indesejáveis, como investimentos equivocados, perda de clientes e redução da eficiência operacional. A ausência de dados confiáveis compromete a capacidade de uma organização de responder adequadamente às mudanças do mercado e de tomar decisões estratégicas eficazes (STONE et al., 2019).

Outro impacto importante é a perda de competitividade. A incapacidade de utilizar os dados de maneira eficaz prejudica a inovação e limita as vantagens competitivas. Por outro lado, empresas que conseguem extrair insights valiosos de seus dados têm a oportunidade de otimizar preços, desenvolver novos produtos e serviços e personalizar a experiência do cliente, conquistando uma posição de destaque no mercado (REDMAN, 1998).

Além disso, a gestão inadequada de dados pode levar ao aumento de custos operacionais. Problemas como a proliferação de silos de dados, a duplicação de informações e a falta de padronização resultam em custos mais altos de armazenamento, processamento e manutenção. Essas ineficiências podem representar um fardo significativo para

as organizações, limitando seu crescimento e eficiência (REDMAN, 1998).

Por fim, os riscos de segurança e conformidade também são um aspecto crítico. Falhas na proteção de dados podem causar violações de segurança, multas significativas e danos irreparáveis à reputação da organização. Empresas que lidam com dados sensíveis, como informações pessoais de clientes, precisam assegurar a conformidade com regulamentações de privacidade, como a GDPR e a LGPD, além de adotar medidas robustas de segurança para prevenir vazamentos de informações e proteger a privacidade dos usuários (BENFELDT; PERSSON; MADSEN, 2020).

1.2.4 Práticas de Engenharia de Dados

A Engenharia de Dados utiliza diversas práticas essenciais para enfrentar os desafios e extrair o máximo valor dos dados. Uma dessas práticas é a modelagem de dados, que define a estrutura, as relações e os tipos de dados que serão armazenados, garantindo garantindo que os dados sejam organizados de forma lógica e eficiente, facilitando a análise e o processamento (VOLK et al., 2019).

Outra prática crucial é a arquitetura de dados, que define a estrutura geral dos sistemas de dados, incluindo os componentes de hardware e software, os fluxos de dados e os mecanismos de segurança. Uma arquitetura bem projetada deve ser escalável, flexível, segura e atender aos requisitos específicos da organização. Nesse contexto, arquiteturas modernas, como data lakes e data warehouses, são projetadas para lidar com a variedade, o volume e a velocidade dos dados gerados atualmente (VOLK et al., 2019).

A integração de dados desempenha um papel fundamental na combinação de informações provenientes de diversas fontes, com o objetivo de criar uma visão unificada e coesa. O sistema deve ser capaz de integrar os dados extraídos de fontes textuais brutas com outras bases de dados, permitindo uma análise mais abrangente e eficiente. Contudo, um dos grandes desafios para alcançar essa integração é a existência de silos de dados, que atuam como barreiras, fragmentando as informações e dificultando a interoperabilidade entre sistemas. Superar esses silos e interconectar os dados de maneira eficiente é essencial para otimizar processos e garantir que as organizações possam explorar todo o potencial dos dados disponíveis (DOAN et al., 2008).

Além disso, a limpeza e transformação de dados é essencial para corrigir erros, remover inconsistências e tratar valores ausentes, nessa etapa há a necessidade de medidas para detectar e corrigir falhas na qualidade dos dados. A transformação de dados permite convertê-los para o formato desejado, seja por meio de agregação, normalização ou enriquecimento com dados externos. Essas etapas são indispensáveis para assegurar a qualidade dos dados e prepará-los adequadamente para análises (REDMAN, 1998).

Por fim, o gerenciamento de dados engloba a implementação de processos, políticas

e ferramentas que garantem a qualidade, segurança, disponibilidade e integridade dos dados. Esse gerenciamento cobre todo o ciclo de vida dos dados, desde sua coleta até o descarte, e inclui atividades como o gerenciamento de metadados, controle de versões, backup e recuperação. Juntas, essas práticas formam a base para uma abordagem sólida e eficaz em Engenharia de Dados, atendendo às demandas crescentes e complexas das organizações modernas (JAHNKE; ASHER; KERALIS, 2012).

1.3 Data Warehouse

Um data warehouse é um repositório central de dados históricos que são usados para análise e tomada de decisão. Ele é projetado para ser **orientado por assunto, não volátil, integrado e variante no tempo**.

Orientado por assunto Um data warehouse é organizado em torno de assuntos específicos de negócios, como clientes, produtos ou vendas, em vez de processos de negócios ou aplicativos.

Não volátil Os dados em um data warehouse são somente leitura e não são atualizados por transações online.

Integrado Um data warehouse integra dados de várias fontes operacionais, fornecendo uma visão única e consistente dos dados da organização.

Variante no tempo Os dados em um data warehouse incluem um componente de tempo, permitindo aos usuários analisar tendências históricas e fazer previsões.

A necessidade de data warehouses surgiu para suportar análise de dados em larga escala, em contraste com os sistemas OLTP, que são projetados para processar transações simples e frequentes. Enquanto os usuários de sistemas OLTP são principalmente funcionários operacionais que realizam operações diárias e acessam dados detalhados e atualizados, os usuários de data warehouses (OLAP) são geralmente gerentes ou analistas que realizam consultas complexas e análises históricas, acessando dados agregados e resumidos. As diferenças nos objetivos de uso resultam em modelos de dados distintos: OLTP usa esquemas altamente normalizados, enquanto OLAP adota modelos multidimensionais, frequentemente denormalizados, para otimizar a performance de consultas analíticas. Além disso, enquanto OLTP exige alta concorrência e processamento em tempo real, OLAP trabalha com dados lidos periodicamente e com menor volume de acessos simultâneos.

O objetivo de um data warehouse é fornecer aos usuários uma visão completa e precisa dos dados da organização, permitindo que tomem decisões mais informadas. As áreas típicas de aplicação de data warehouses incluem análise de vendas e marketing, gerenciamento de relacionamento com o cliente (CRM), planejamento de recur-

os empresariais (ERP) e inteligência de negócios (BI) ([NAMBIAR; MUNDRA, 2022](#); [VAISMAN; ZIMÁNYI, 2014](#)).

1.3.1 Definição e Conceito

Um data warehouse pode ser definido como uma combinação de conceitos e tecnologias que facilitam a gestão e manutenção de dados históricos obtidos de aplicações operacionais e transacionais. Ele serve como um ambiente que auxilia os tomadores de decisão, como executivos, gerentes e analistas, a tomar decisões mais rápidas e informadas.

Em essência, um data warehouse não é um produto, mas sim um ambiente onde os usuários podem encontrar informações estratégicas. Ele funciona como um repositório centralizado e integrado de informações, extraídas de dados dispersos em diversos sistemas, com o propósito de auxiliar na tomada de decisões.

O data warehouse se diferencia de um banco de dados operacional por ser um resumo lógico dos dados, separado do banco de dados transacional. Ele permite a integração de diversos tipos de dados de diferentes aplicações ou sistemas, proporcionando um mecanismo de acesso unificado para que a gestão obtenha informações e as analise para a tomada de decisão ([SANTOSO; YULIA, 2017](#)).

1.3.2 Arquitetura

A arquitetura de um Data Warehouse é composta por várias camadas interconectadas, que trabalham em conjunto para garantir a eficiência na coleta, transformação e análise de grandes volumes de dados. A figura 1 ilustra as principais camadas de uma arquitetura geral de um Data Warehouse.

A arquitetura apresentada é composta por quatro camadas principais:

Camada de Back-End Responsável pelos processos de extração, transformação e carga (ETL) dos dados. Aqui, os dados são extraídos de fontes heterogêneas, transformados para o formato adequado e carregados no Data Warehouse. Essa camada também pode envolver o uso de uma área de staging, onde os dados extraídos são temporariamente armazenados e processados antes de sua inserção no repositório central de dados.

Camada do Data Warehouse Composta pelo Data Warehouse (armazém de dados centralizado) e por Data Marts (armazéns de dados especializados em áreas específicas). Além disso, essa camada inclui o repositório de metadados, que armazena informações sobre a estrutura e os processos do Data Warehouse.

Camada OLAP (Online Analytical Processing) Esta camada envolve o uso de servidores OLAP, que permitem a exploração multidimensional dos dados armazenados

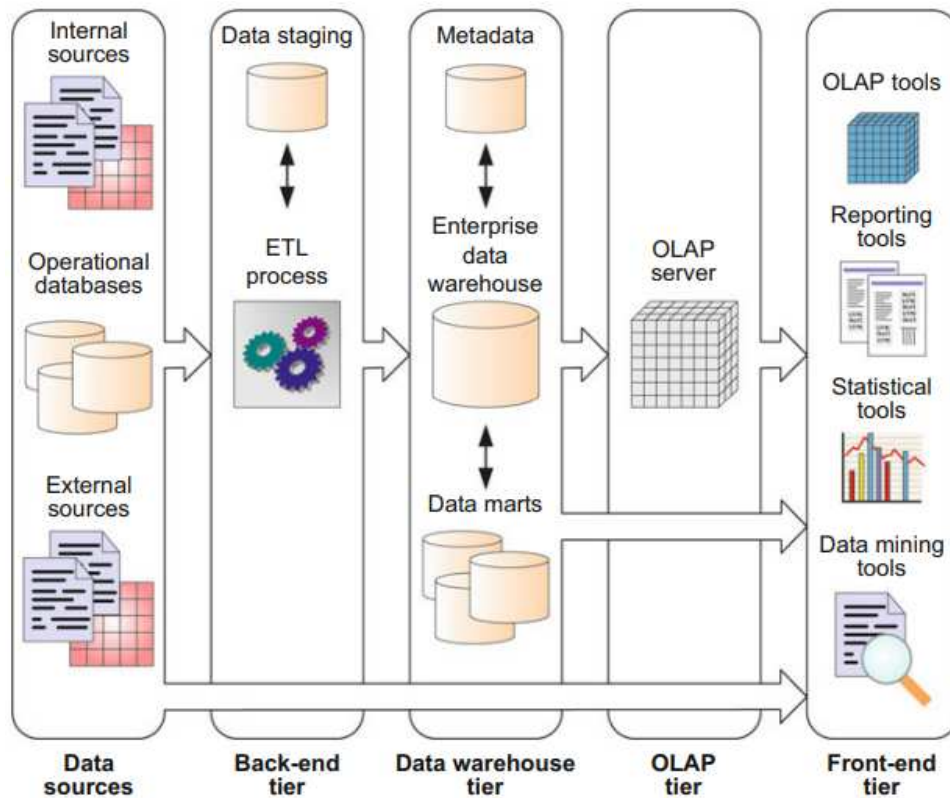


Figura 1 – Arquitetura geral de um Data Warehouse

no Data Warehouse. O OLAP facilita a análise de grandes volumes de dados de maneira interativa e flexível, utilizando cubos de dados e outras estruturas analíticas.

Camada Front-End Responsável pelas ferramentas utilizadas para análise e visualização dos dados. Inclui ferramentas OLAP, ferramentas de relatórios, ferramentas estatísticas e de mineração de dados, que permitem a exploração dos dados de forma interativa e a geração de insights valiosos para a tomada de decisões empresariais.

(VAISMAN; ZIMÁNYI, 2014)

1.3.3 Quando Utilizar

A implementação de um data warehouse é amplamente recomendada em contextos onde as organizações precisam tomar decisões estratégicas baseadas em grandes volumes de dados históricos provenientes de diversas fontes. A necessidade de analisar tendências, identificar padrões e extrair insights estratégicos, que não são acessíveis por meio de sistemas transacionais tradicionais, justifica a adoção dessa tecnologia.

O data warehouse desempenha um papel essencial em cenários específicos. Por exemplo, quando os dados estão dispersos em diferentes sistemas, o que dificulta a obtenção de uma visão unificada da organização, o data warehouse se torna uma solução

eficiente. Ele possibilita a integração de dados de múltiplas fontes, fornecendo uma visão única e consistente das informações organizacionais. Além disso, sua capacidade de armazenar dados históricos permite a análise aprofundada de tendências e padrões ao longo do tempo, fator indispensável para decisões baseadas em informações históricas (SANTOSO; YULIA, 2017).

Outro aspecto relevante é que organizações frequentemente necessitam de relatórios e análises complexas, que não podem ser gerados de forma eficaz por sistemas transacionais. Nesse contexto, o data warehouse, projetado especificamente para consultas e análises sofisticadas, oferece suporte à criação de relatórios detalhados e dashboards interativos. Ademais, ao fornecer um ambiente separado para análises, ele evita impactos no desempenho dos sistemas operacionais, cuja principal função é suportar as operações diárias da organização (SANTOSO; YULIA, 2017).

Embora os benefícios de um data warehouse sejam inegáveis, sua implementação exige uma avaliação cuidadosa dos custos e benefícios envolvidos. Trata-se de um processo que pode ser complexo, demorado e custoso, requerendo investimentos significativos em infraestrutura, software e equipes especializadas. Apesar disso, quando bem implementado, o data warehouse pode proporcionar vantagens significativas, como a melhoria na qualidade da tomada de decisões, por meio do fornecimento de informações precisas e oportunas, além de ganhos em eficiência operacional, resultantes da otimização de processos baseada nos insights obtidos. Por fim, ele pode oferecer uma vantagem competitiva à organização, ao permitir análises preditivas que ajudam a antecipar tendências e oportunidades de mercado (VAISMAN; ZIMÁNYI, 2014; MOUSA; SHIRATUDDIN, 2015).

1.3.4 Quando Não Utilizar

A implementação de um Data Warehouse, embora amplamente vantajosa em diversos contextos, apresenta limitações e desafios que podem torná-lo inadequado para determinados cenários. Um dos principais problemas está relacionado ao tempo e à complexidade do processo de ETL. Muitas vezes, os desenvolvedores não consideram adequadamente o tempo necessário para realizar essas etapas, resultando no esgotamento de grande parte do tempo destinado à construção do sistema. Essa situação pode gerar atrasos e custos inesperados, especialmente em projetos com cronogramas restritos.

Além disso, o modelo de design do Data Warehouse pode ser extremamente complexo e não reflexivo, dificultando sua adaptação às necessidades de negócios em constante mudança. Isso ocorre porque, ao adicionar novas fontes de dados ou realizar alterações nos processos, os designers do Data Warehouse frequentemente precisam redesenhar o ETL, resultando em modificações nas regras ou nas origens dos dados, o que aumenta a complexidade e o custo do sistema.

Outra limitação importante está na atualização do Data Warehouse, que geralmente é feita de forma offline. Isso significa que, enquanto o sistema é atualizado, as aplicações de BI não conseguem acessar os dados ou fornecer informações em tempo real. Esse atraso pode ser prejudicial para empresas que dependem de análises e tomadas de decisão imediatas, como em cenários de operações críticas ou de alta competitividade no mercado.

Ademais, o armazenamento de dados no Data Warehouse implica em custos adicionais. Como o Data Warehouse é uma cópia dos dados originais, ele requer um espaço físico maior para armazenamento, o que pode gerar custos elevados com licenciamento, manutenção e resposta a demandas de infraestrutura ([MOUSA; SHIRATUDDIN, 2015](#)).

1.4 Data Fabric

A crescente proliferação de dados em formatos e plataformas diversas apresenta um desafio significativo para as organizações. A necessidade de integrar, gerenciar e analisar esses dados de forma eficiente impulsionou a busca por soluções inovadoras. É nesse contexto que surge o conceito de Data Fabric, uma arquitetura emergente que visa unificar e simplificar o acesso e o uso de dados em todo o ecossistema de uma organização. Data Fabric pode ser definida como uma estrutura unificada e flexível, independente de plataformas e tecnologias, que conecta diferentes fontes de dados, permitindo o acesso e a análise de forma ágil e eficiente ([GADE, 2022](#)). Essa arquitetura utiliza metadados para construir um conhecimento abrangente sobre os dados, facilitando sua descoberta, acesso e governança ([BARIK, 2022](#)).

Em sua essência, o Data Fabric visa:

- Superar os desafios dos silos de dados, integrando dados de diferentes fontes e formatos ([GADE, 2022](#)).
- Criar uma visão holística e unificada dos dados da organização ([BARIK, 2022](#)).
- Simplificar o acesso e a análise de dados, permitindo que usuários de negócios acessem os dados de que precisam de forma autônoma e segura ([GADE, 2022](#)).
- Garantir a governança e a conformidade dos dados, aplicando políticas e regras de forma consistente em todo o ambiente de dados ([GADE, 2022](#)).

O Data Fabric representa uma mudança de paradigma na gestão de dados, evoluindo de abordagens tradicionais e fragmentadas para um modelo unificado e inteligente.

1.4.1 Definição e Conceito

O Gartner define o Data Fabric como "um conceito de design que atua como uma camada integrada (fabric) de dados e processos de conexão. Essa camada utiliza análises contínuas sobre metadados existentes, detectáveis e inferidos para dar suporte ao design, implantação e utilização de dados integrados e reutilizáveis em todos os ambientes, incluindo plataformas híbridas e multinuvem" (Gartner, 2024). Em outras palavras, o Data Fabric visa conectar e fornecer uma visão holística dos ativos de dados em toda a empresa, utilizando metadados para descoberta, acesso e uso de dados de forma self-service (BARIK, 2022).

O conceito de Data Fabric surgiu com o objetivo de conectar diferentes fontes de dados, em diferentes formatos e plataformas, de forma eficiente (BLOHM et al., 2024). A ideia é criar uma camada de abstração que permita aos usuários acessar e analisar os dados sem se preocupar com a complexidade da infraestrutura subjacente (BARIK, 2022).

O Data Fabric surge como uma evolução das plataformas de dados corporativos, aproveitando capacidades existentes e adicionando funcionalidades para criar uma rede integrada de informações. Ele não exige a consolidação física dos dados, mas utiliza metadados para conectar e permitir acesso a dados em diferentes repositórios, mantendo os sistemas em suas infraestruturas originais. Isso contrasta com plataformas centralizadas, que demandam a movimentação e agregação de dados em um único local (BARIK, 2022).

1.4.2 Arquitetura

A arquitetura do Data Fabric é complexa e não existe um modelo único que atenda a todas as necessidades. No entanto, podemos identificar alguns componentes chave e princípios de design comuns a maioria das implementações.

Componentes da Arquitetura:

- **Camada de Fontes de Dados:** O Data Fabric se conecta a uma variedade de fontes de dados, incluindo bancos de dados relacionais, bancos de dados NoSQL, data lakes, sistemas de arquivos e APIs. O Data Fabric abstrai a complexidade dessas fontes, permitindo que os usuários acessem os dados de forma uniforme, independentemente de sua localização ou formato (BARIK, 2022).
- **Camada de Ingestão e Integração de Dados:** Responsável por coletar, transformar e integrar dados de diferentes fontes. O Data Fabric utiliza uma variedade de técnicas de integração de dados, como virtualização de dados, replicação de dados e ETL (Extract, Transform, Load). A escolha da técnica mais adequada depende das características dos dados, dos requisitos de desempenho e dos custos (BARIK, 2022).

- **Camada de Metadados:** O Data Fabric mantém um catálogo abrangente de metadados que descrevem os dados, incluindo seu significado, relacionamento com outros dados e como podem ser usados. O Data Fabric utiliza inteligência artificial (IA) e machine learning (ML) para automatizar a descoberta, classificação e enriquecimento de metadados. Essa camada é crucial para a descoberta de dados, governança de dados e self-service (BARIK, 2022).
- **Camada de Processamento e Análise de Dados:** O Data Fabric fornece um ambiente para processar e analisar dados, utilizando uma variedade de ferramentas e tecnologias, como Spark, Hadoop e plataformas de machine learning. Essa camada pode ser implementada em diferentes ambientes, como on-premises, cloud ou edge (SHARMA et al., 2023).
- **Camada de Acesso e Consumo de Dados:** O Data Fabric fornece uma interface unificada para acessar e consumir dados, por meio de APIs, ferramentas de visualização de dados e dashboards. Essa camada permite que os usuários de negócios acessem os dados de que precisam de forma self-service, sem a necessidade de envolver a equipe de TI (BARIK, 2022).

Princípios de Design:

- **Descentralização:** O Data Fabric é uma arquitetura descentralizada, o que significa que os dados podem permanecer em seus locais originais, eliminando a necessidade de criar um repositório centralizado de dados. Isso torna o Data Fabric mais flexível e escalável (SHARMA et al., 2023).
- **Elasticidade e Escalabilidade:** O Data Fabric é projetada para ser elástica e escalável, permitindo que as organizações adicionem ou removam recursos de computação e armazenamento conforme necessário. Isso garante que o Data Fabric possa lidar com o crescimento do volume e da variedade de dados (SHARMA et al., 2023).
- **Segurança e Governança:** O Data Fabric implementa políticas e regras de segurança e governança de dados de forma consistente em todo o ambiente de dados, garantindo a conformidade com as regulamentações (SHARMA et al., 2023).
- **Inteligência Artificial e Automação:** O Data Fabric utiliza IA e ML para automatizar tarefas de gerenciamento de dados, como a descoberta, classificação e enriquecimento de dados. Isso torna o Data Fabric mais eficiente e inteligente, permitindo que as organizações extraiam o máximo valor de seus dados (HECHLER; WEIHRAUCH; 2023).

A arquitetura do Data Fabric é projetada para fornecer uma plataforma unificada e inteligente para gerenciar dados em todo o ecossistema de uma organização. Ao com-

binar os princípios de descentralização, elasticidade, segurança, governança e inteligência artificial, o Data Fabric capacita as organizações a aproveitar ao máximo o valor de seus dados, impulsionando a tomada de decisões e a inovação.

1.4.3 Quando Utilizar

Após explorar a arquitetura do Data Fabric, é crucial entender em quais cenários e situações essa abordagem se torna especialmente vantajosa. O Data Fabric não é uma solução universal para todos os problemas de dados, mas sim uma ferramenta poderosa que, quando aplicada corretamente, pode gerar grande valor para as organizações.

O Data Fabric é especialmente útil em organizações que enfrentam desafios na gestão de dados, como a unificação de dados altamente inter-relacionados, mas dispersos em diferentes sistemas. Ela atua como uma camada integradora, simplificando o acesso e análise desses dados. Além disso, ajuda a superar barreiras causadas por silos de dados, promovendo uma visão unificada e melhor colaboração entre equipes ([BARIK, 2022](#)).

Empresas com múltiplas plataformas de dados, como data lakes e warehouses, podem usá-la para criar um ambiente de dados coeso e gerenciável. Sua arquitetura flexível e escalável permite adaptar-se rapidamente a mudanças nos requisitos de negócios, promovendo agilidade.

O Data Fabric também facilita a democratização dos dados, oferecendo suporte para análises self-service com segurança e governança adequadas. Por fim, possibilita a aplicação consistente de políticas de governança em todo o ambiente de dados, garantindo qualidade, segurança e conformidade de maneira automatizada. Assim, ela se apresenta como uma solução estratégica para integrar, gerenciar e governar dados em cenários complexos.

1.4.4 Quando Não Utilizar

Embora o Data Fabric apresente um potencial transformador para a gestão de dados em diversos cenários, existem situações em que sua implementação pode não ser a escolha mais adequada. A decisão de adotar uma arquitetura de Data Fabric deve ser baseada em uma análise cuidadosa das necessidades, recursos e desafios da organização.

Um dos cenários em que o Data Fabric pode não ser a melhor opção é quando organizações possui baixo volume de dados com pouca variedade, o Data Fabric podem não justificar o investimento e o esforço de implementação. Soluções de gerenciamento de dados mais simples e tradicionais podem ser suficientes nesses casos ([BARIK, 2022](#)).

Outro cenário desafiador é a falta de maturidade em governança de dados. A eficácia do Data Fabric depende de processos bem estabelecidos de qualidade, segurança

e conformidade, o que torna sua implementação mais complexa em empresas que ainda não possuem uma base sólida nesse aspecto (GADE, 2022).

Além disso, a adoção dessa arquitetura pode enfrentar desafios importantes. A escassez de profissionais qualificados para projetar, implementar e gerenciar sistemas avançados de Data Fabric pode dificultar sua implementação, levando a atrasos e à dependência de consultores externos. Além disso, a resistência cultural à mudança representa outro obstáculo, especialmente entre colaboradores acostumados a sistemas e processos existentes. Superar esses desafios exige uma gestão de mudanças robusta, que promova a compreensão dos benefícios do Data Fabric e incentive uma cultura de inovação e adaptação dentro das organizações (GADE, 2022).

1.5 Data Lake

Os **data lakes** são **repositórios escaláveis** projetados para armazenar **grandes volumes de dados brutos em seus formatos nativos até que sejam necessários**. Diferentemente de bancos de dados tradicionais, que lidam principalmente com dados estruturados e frequentemente escalam verticalmente, os data lakes foram concebidos para gerenciar o **volume, velocidade e variedade de dados**, incluindo dados estruturados, semiestruturados e não estruturados (FANG, 2021).

Características Principais dos Data Lakes

- **Arquitetura escalável:** Utilizam escalonamento horizontal, distribuindo a carga entre várias máquinas ou nós, o que permite gerenciar grandes volumes de dados difíceis de serem administrados em sistemas tradicionais (GONZALEZ, 2019).
- **Compatibilidade com tecnologias modernas:** São implementados com sistemas de arquivos distribuídos como o **HDFS** ou serviços de armazenamento em nuvem, como **Amazon S3**, **Azure Data Lake Storage Gen2** e **Google Cloud Storage** (VASS; STEWART, 2020).

Vantagens dos Data Lakes

- **Custo-benefício:** Aproveitam hardware comum e armazenamento em nuvem, reduzindo custos em comparação aos data warehouses tradicionais (ZAGAN; DANUBIANU, 2020).
- **Flexibilidade:** Permitem armazenar dados em formatos diversos sem a necessidade de transformações iniciais, facilitando análises futuras (ZAGAN; DANUBIANU, 2020).

- **Escalabilidade:** São projetados para crescer horizontalmente, acomodando volumes crescentes e fontes de dados variadas (ZAGAN; DANUBIANU, 2020).

Desvantagens dos Data Lakes

- **Confiabilidade dos dados:** Sem gestão adequada, podem se transformar em "pântanos de dados" devido à falta de controle de qualidade, gerenciamento de esquemas e proteções transacionais (NUTHALAPATI, 2018).
- **Desempenho:** Consultas em dados brutos podem ser lentas e ineficientes (NUTHALAPATI, 2018).
- **Complexidade de gestão:** Exigem habilidades e ferramentas especializadas para administração e segurança (NUTHALAPATI, 2018).

1.5.1 Tabela Comparativa: Data Lakes vs. Bancos de Dados Tradicionais

Característica	Data Lakes	Bancos de Dados Tradicionais
Estrutura de Dados	Suporta formatos diversos (estruturados, semiestruturados e não estruturados)	Projetados para dados estruturados
Escalabilidade	Escalabilidade horizontal	Escalabilidade vertical
Custo	Mais econômico com uso de hardware comum e nuvem	Mais caro devido a hardware e software especializados
Flexibilidade	Alta flexibilidade para diferentes formatos e esquemas	Menos flexível, requer esquemas definidos previamente
Confiabilidade	Suscetível a problemas de qualidade sem gestão	Alta confiabilidade com propriedades ACID

1.6 Data Mesh: Um Paradigma para Gestão de Dados Descentralizados

O **Data Mesh** é uma abordagem descentralizada para a arquitetura de dados, introduzida como uma alternativa aos modelos centralizados tradicionais, como **Data Warehouses** e **Data Lakes**. Essa abordagem foca na distribuição de responsabilidades para equipes de domínio, promovendo escalabilidade e autonomia (DEHGHANI, 2020).

1.6.1 O que é Data Mesh?

O conceito de *Data Mesh* se baseia na ideia de tratar dados como produtos gerenciados por equipes de domínio, que são especialistas em seus próprios casos de uso. A arquitetura enfatiza a governança distribuída, onde os nós representam *data products* e as conexões entre eles facilitam a integração (AKHTAR, 2021).

1.6.2 Princípios Fundamentais do Data Mesh

O *Data Mesh* baseia-se em quatro princípios fundamentais:

1. **Propriedade de Dados Descentralizada e Orientada ao Domínio:** As equipes de domínio são responsáveis pelos dados que produzem, garantindo sua qualidade e acessibilidade (DEHGHANI, 2020).
2. **Dados como Produto:** Os dados são tratados como produtos independentes, com seus próprios responsáveis que garantem governança e facilidade de consumo (DEHGHANI, 2020).
3. **Plataforma de Dados Autossuficiente:** Uma infraestrutura centralizada abstrai a complexidade técnica, permitindo que equipes de domínio operem com eficiência (AKHTAR, 2021).
4. **Governança Federada:** Diretrizes centrais são aplicadas localmente pelas equipes, promovendo consistência e autonomia (MARTINEZ, 2022).

1.6.3 Vantagens e Desvantagens do Data Mesh

O *Data Mesh* apresenta vantagens significativas, como escalabilidade horizontal e maior agilidade organizacional. No entanto, também possui desafios, como a necessidade de equipes técnicas autônomas e de uma infraestrutura robusta para suportar a descentralização (JOHNSON, 2021).

1.6.4 Quando Utilizar Data Mesh?

O *Data Mesh* é indicado em:

- **Organizações complexas:** Grandes organizações com múltiplos domínios de dados (DEHGHANI, 2020).
- **Cenários de alta escalabilidade:** Empresas em rápido crescimento de volume de dados (MARTINEZ, 2022).

1.6.5 Quando Não Utilizar Data Mesh?

Evite *Data Mesh* em:

- **Pequenas organizações:** Onde os dados centralizados são mais fáceis de gerenciar ([JOHNSON, 2021](#)).
- **Ambientes com baixa maturidade em dados:** A descentralização pode ser excessivamente complexa ([AKHTAR, 2021](#)).

1.6.6 Ferramentas Open Source para Data Mesh

Diversas ferramentas podem ser integradas ao *Data Mesh*:

- **Apache Airflow:** Para orquestração de pipelines de dados.
- **Apache Kafka:** Para ingestão e streaming de dados em tempo real.
- **dbt (Data Build Tool):** Para transformação e documentação de dados.
- **Kubernetes:** Para implantação escalável de serviços de dados ([SMITH, 2023](#)).

1.6.7 Conclusão

O *Data Mesh* representa uma evolução na arquitetura de dados, oferecendo soluções para os desafios da centralização. No entanto, sua implementação exige uma infraestrutura bem projetada e equipes capacitadas.

1.7 Apache Airflow: Orquestração de Pipelines

O Apache Airflow é uma plataforma de orquestração de workflows de código aberto que permite programar, executar e monitorar pipelines de dados de forma programática. Desenvolvido originalmente pelo Airbnb em 2014 e posteriormente doado à Apache Software Foundation, o Airflow se tornou uma ferramenta essencial para a automação e gerenciamento de fluxos de trabalho complexos em ambientes de processamento de dados ([CHANG; SHARMA, 2021](#)).

1.7.1 Conceitos Fundamentais

O Airflow utiliza Directed Acyclic Graphs (DAGs) para representar workflows, onde cada nó é uma tarefa e as arestas definem as dependências entre elas. Esta estrutura permite uma visualização clara do fluxo de trabalho e suas dependências, facilitando o gerenciamento e a manutenção dos pipelines ([GARCIA; LUMBRERAS, 2021](#)).

Os principais componentes do Airflow incluem:

- **DAGs (Directed Acyclic Graphs):** Representação dos workflows como grafos direcionados acíclicos
- **Operators:** Componentes que definem o que realmente será executado em cada tarefa
- **Tasks:** Instâncias parametrizadas de operadores
- **Dependencies:** Relações entre tarefas que determinam a ordem de execução

1.7.2 Características Principais

O Apache Airflow oferece diversas características que o tornam uma escolha popular para orquestração de pipelines (KUMAR; SINGH, 2022):

1. **Escalabilidade:** Suporta a execução distribuída de tarefas através de workers
2. **Extensibilidade:** Permite a criação de operadores e hooks personalizados
3. **Interface Web:** Fornece uma interface intuitiva para monitoramento e gerenciamento de DAGs
4. **Versionamento:** Integra-se facilmente com sistemas de controle de versão
5. **Recuperação de Falhas:** Oferece mecanismos robustos para retry e recuperação de erros

1.7.3 Arquitetura

A arquitetura do Airflow é composta por vários componentes que trabalham em conjunto (SHARMA; GUPTA, 2021):

- **Scheduler:** Responsável por agendar e disparar a execução das tarefas
- **Executor:** Determina como as tarefas serão executadas
- **Web Server:** Fornece a interface gráfica para interação com o sistema
- **Metadata Database:** Armazena metadados sobre DAGs, execuções e configurações
- **Workers:** Executam as tarefas em ambientes distribuídos

1.7.4 Benefícios e Limitações

1.7.4.1 Benefícios

- Configuração como código (Configuration as Code)
- Monitoramento e logging abrangentes
- Comunidade ativa e grande ecossistema de plugins
- Suporte a múltiplos executores e provedores de nuvem

1.7.4.2 Limitações

- Complexidade inicial de configuração
- Consumo significativo de recursos em ambientes grandes
- Curva de aprendizado íngreme para recursos avançados

1.7.5 Melhores Práticas

Para uma utilização efetiva do Airflow, algumas práticas são recomendadas ([FOUNDATION, 2023](#)):

1. **Atomicidade:** Criar tarefas atômicas e idempotentes
2. **Idempotência:** Garantir que múltiplas execuções produzam o mesmo resultado
3. **Documentação:** Manter documentação clara e atualizada dos DAGs
4. **Tratamento de Erros:** Implementar estratégias robustas de retry e fallback
5. **Monitoramento:** Configurar alertas e métricas adequadas

1.8 Kubernetes: Orquestração de Containers para Escalabilidade

O Kubernetes (K8s) é uma plataforma de código aberto para orquestração de containers, originalmente desenvolvida pelo Google e posteriormente doada à Cloud Native Computing Foundation (CNCF). Esta plataforma automatiza a implantação, o dimensionamento e o gerenciamento de aplicações containerizadas, tornando-se um padrão de facto na indústria para orquestração de containers em larga escala ([BURNS; BEDA; HIGHTOWER, 2019](#)).

1.8.1 Arquitetura do Kubernetes

A arquitetura do Kubernetes é baseada em um modelo master-node (também conhecido como control plane e worker nodes), onde cada componente tem responsabilidades específicas ([VERMA; PEDROSA; KORUPOLU, 2020](#)):

1.8.1.1 Control Plane (Master)

- **kube-apiserver**: Expõe a API do Kubernetes e atua como frontend do cluster
- **etcd**: Armazenamento consistente e distribuído para todos os dados do cluster
- **kube-scheduler**: Responsável por agendar pods nos nodes do cluster
- **kube-controller-manager**: Executa os processos de controle do cluster

1.8.1.2 Worker Nodes

- **kubelet**: Agente que garante que os containers estejam rodando em um pod
- **kube-proxy**: Mantém as regras de rede nos nodes
- **Container Runtime**: Software responsável por executar os containers

1.8.2 Conceitos Fundamentais

O Kubernetes opera com diversos conceitos fundamentais que formam a base de sua funcionalidade ([HIGHTOWER; BURNS; BEDA, 2019](#)):

1. **Pods**: A menor unidade implantável no Kubernetes, que pode conter um ou mais containers
2. **Services**: Abstração que define um conjunto lógico de pods e uma política de acesso
3. **Deployments**: Gerencia a criação e atualização de réplicas de pods
4. **StatefulSets**: Gerencia aplicações stateful com identidades persistentes
5. **ConfigMaps e Secrets**: Gerenciam configurações e dados sensíveis

1.8.3 Recursos de Escalabilidade

O Kubernetes oferece diversos mecanismos para garantir a escalabilidade das aplicações ([LUKSA, 2021](#)):

1.8.3.1 Escalabilidade Horizontal

- **Horizontal Pod Autoscaling (HPA):** Ajusta automaticamente o número de pods baseado em métricas
- **Cluster Autoscaling:** Adiciona ou remove nodes automaticamente conforme a demanda
- **Load Balancing:** Distribui o tráfego entre múltiplas instâncias de aplicação

1.8.3.2 Alta Disponibilidade

- **Self-healing:** Reinicia containers que falham, substitui e reagenda containers
- **Rolling Updates:** Permite atualizações sem downtime
- **Multi-zone Deployment:** Distribui a carga entre diferentes zonas de disponibilidade

1.8.4 Benefícios e Desafios

1.8.4.1 Benefícios

1. **Portabilidade:** Funciona em qualquer ambiente (on-premise, nuvem ou híbrido)
2. **Escalabilidade:** Gerenciamento automático de recursos e carga
3. **Resiliência:** Recuperação automática de falhas
4. **Declarativo:** Configuração como código (Infrastructure as Code)

1.8.4.2 Desafios

1. **Complexidade:** Curva de aprendizado íngreme
2. **Overhead Operacional:** Requer equipe especializada para manutenção
3. **Custos:** Pode ser dispendioso em ambientes pequenos
4. **Segurança:** Requer atenção especial à configuração de segurança

1.8.5 Melhores Práticas

Para uma implementação efetiva do Kubernetes, algumas práticas são recomendadas ([ARUNDEL; DOMINGUS, 2021](#)):

- **Segurança:** Implementar políticas de segurança e network policies
- **Monitoramento:** Utilizar ferramentas como Prometheus e Grafana
- **Logging:** Centralizar logs com soluções como ELK Stack
- **Resource Management:** Definir limites e requisitos de recursos
- **Backup:** Implementar estratégias de backup e disaster recovery

1.9 FastAPI: Desenvolvimento de APIs para Integração de Dados

FastAPI é um framework moderno e de alto desempenho para construção de APIs com Python, baseado em padrões como OpenAPI (anteriormente conhecido como Swagger) e JSON Schema. Desenvolvido por Sebastián Ramírez, o FastAPI se destaca por sua velocidade de execução, facilidade de uso e geração automática de documentação interativa ([RAMÍREZ, 2023](#)).

1.9.1 Características Fundamentais

O FastAPI possui características que o tornam particularmente adequado para integração de dados ([RAMÍREZ; GONZÁLEZ, 2022](#)):

1. **Performance:** Baseado no ASGI (Asynchronous Server Gateway Interface) e no Starlette
2. **Tipagem Estática:** Utiliza type hints do Python para validação automática
3. **Documentação Automática:** Gera documentação interativa OpenAPI e ReDoc
4. **Async/Await:** Suporte nativo a programação assíncrona
5. **Validação de Dados:** Baseada no Pydantic para validação e serialização

1.9.2 Arquitetura e Componentes

A arquitetura do FastAPI é construída sobre componentes modernos e eficientes ([KUMAR; SINGH, 2023b](#)):

1.9.2.1 Componentes Principais

- **Starlette:** Framework ASGI leve para aplicações assíncronas
- **Pydantic:** Biblioteca para validação de dados usando type annotations

- **Uvicorn**: Servidor ASGI de alto desempenho
- **OpenAPI**: Especificação para documentação de APIs RESTful

1.9.3 Integração de Dados com FastAPI

O FastAPI oferece recursos robustos para integração de dados ([WILSON, 2023](#)):

1.9.3.1 Modelos de Dados

```
from pydantic import BaseModel

class DataModel(BaseModel):
    id: int
    name: str
    value: float
```

1.9.3.2 Endpoints para Manipulação de Dados

- **CRUD Operations**: Implementação simplificada de operações básicas
- **Batch Processing**: Processamento eficiente de grandes conjuntos de dados
- **Streaming**: Suporte a streaming de dados em tempo real
- **Background Tasks**: Processamento assíncrono de tarefas pesadas

1.9.4 Segurança e Autenticação

FastAPI oferece diversos mecanismos de segurança ([BROWN; JOHNSON, 2023](#)):

1. **OAuth2**: Suporte nativo a OAuth2 com diferentes fluxos
2. **JWT**: Integração com JSON Web Tokens
3. **API Keys**: Autenticação via chaves de API
4. **CORS**: Configuração flexível de Cross-Origin Resource Sharing

1.9.5 Performance e Escalabilidade

O FastAPI se destaca em termos de performance ([PETERSON; LEE, 2023](#)):

1.9.5.1 Métricas de Desempenho

- Baixa latência em requisições HTTP
- Alta capacidade de processamento concorrente
- Uso eficiente de recursos computacionais
- Excelente desempenho em operações I/O-bound

1.9.6 Melhores Práticas

Para um desenvolvimento eficiente com FastAPI, recomenda-se ([MARTINEZ; THOMPSON, 2023](#)):

1. Estruturação do Projeto

- Organização modular do código
- Separação clara de responsabilidades
- Uso de dependency injection

2. Tratamento de Erros

- Implementação de exception handlers
- Respostas de erro padronizadas
- Logging adequado

3. Documentação

- Documentação clara dos endpoints
- Exemplos de uso
- Descrições detalhadas dos modelos de dados

1.9.7 Limitações e Considerações

Apesar de suas vantagens, é importante considerar algumas limitações ([KUMAR; SINGH, 2023b](#)):

- Necessidade de conhecimento em programação assíncrona
- Curva de aprendizado para recursos avançados
- Complexidade adicional em projetos muito grandes
- Dependência do ecossistema Python

1.10 Pipelines de Dados no Diagnóstico de Câncer de Pele

O desenvolvimento de pipelines de dados para o diagnóstico de câncer de pele representa uma interseção crucial entre a engenharia de dados e a medicina. Estes pipelines são projetados para processar, analisar e gerenciar grandes volumes de imagens dermatológicas, auxiliando no diagnóstico precoce e preciso de diferentes tipos de câncer de pele (ZHANG; WANG; SINGH, 2021).

1.10.1 Arquitetura do Pipeline

A arquitetura de um pipeline de dados para diagnóstico de câncer de pele tipicamente inclui várias etapas interconectadas (ESTEVA; TOPOL, 2022):

1. Aquisição de Dados

- Captação de imagens dermatológicas
- Digitalização de prontuários médicos
- Metadados clínicos associados

2. Pré-processamento

- Normalização de imagens
- Remoção de ruídos
- Segmentação de lesões
- Augmentação de dados

3. Processamento

- Extração de características
- Análise de textura e cor
- Classificação de lesões

4. Armazenamento e Recuperação

- Banco de dados de imagens
- Sistema de cache
- Backup e redundância

1.10.2 Componentes Essenciais

Os componentes fundamentais do pipeline incluem (KUMAR; PATEL, 2023):

1.10.2.1 Infraestrutura de Dados

- **Storage Layer:** Armazenamento distribuído para grandes volumes de imagens
- **Processing Layer:** Recursos computacionais para processamento de imagens
- **Analytics Layer:** Ferramentas para análise e visualização

1.10.2.2 Modelos de Processamento

- **Redes Neurais Convolucionais (CNN)**
- **Algoritmos de Segmentação**
- **Modelos de Classificação**

1.10.3 Fluxo de Dados e Processamento

O fluxo de dados em um pipeline de diagnóstico de câncer de pele segue um processo estruturado ([WANG; CHEN, 2023](#)):

1. Ingestão de Dados

- Coleta de imagens dermatoscópicas
- Validação de qualidade da imagem
- Padronização de formato

2. Pré-processamento de Imagens

- Normalização de contraste e brilho
- Remoção de artefatos
- Segmentação da região de interesse

3. Análise e Classificação

- Extração de características
- Aplicação de modelos de ML/DL
- Geração de predições

1.10.4 Garantia de Qualidade

A qualidade dos dados é crucial para o diagnóstico preciso ([SMITH; BROWN, 2023a](#)):

- **Controle de Qualidade de Imagem**

- Verificação de resolução
- Análise de contraste
- Validação de formato

- **Validação de Dados**

- Verificação de completude
- Consistência de metadados
- Integridade dos dados

1.10.5 Desafios e Considerações

O desenvolvimento de pipelines para diagnóstico de câncer de pele enfrenta diversos desafios ([CHEN; MARTINEZ, 2023](#)):

1. Desafios Técnicos

- Variabilidade na qualidade das imagens
- Necessidade de processamento em tempo real
- Requisitos de armazenamento

2. Desafios Clínicos

- Variabilidade das lesões
- Necessidade de alta precisão
- Interpretabilidade dos resultados

3. Considerações Éticas

- Privacidade dos pacientes
- Segurança dos dados
- Conformidade regulatória

1.11 Fluxo de Dados em Arquitetura de Data Fabric

Em uma arquitetura de Data Fabric, o fluxo de dados é projetado para proporcionar uma integração contínua e inteligente de dados através de múltiplos ambientes, garantindo consistência, governança e acessibilidade ([SHARMA et al., 2023](#)). Este modelo representa uma evolução significativa na forma como as organizações gerenciam e utilizam seus dados, especialmente em ambientes híbridos e distribuídos.

1.11.1 Componentes do Fluxo de Dados

O fluxo de dados em uma arquitetura Data Fabric é composto por diversos componentes interconectados ([HECHLER; WEIHRAUCH; WU, 2023](#)):

1. Camada de Ingestão

- Conectores de fonte de dados
- Mecanismos de streaming
- APIs de integração
- Protocolos de comunicação

2. Camada de Processamento

- Transformação de dados
- Validação e limpeza
- Enriquecimento de dados
- Normalização

3. Camada de Armazenamento

- Data Lakes
- Data Warehouses
- Bancos de dados distribuídos
- Sistemas de cache

1.11.2 Padrões de Fluxo de Dados

Os padrões de fluxo de dados em uma arquitetura Data Fabric podem ser categorizados em diferentes tipos ([BLOHM et al., 2024](#)):

1.11.2.1 Fluxo Batch

- Processamento em lotes programados
- Transformações complexas
- Agregações de grande escala
- Cargas incrementais

1.11.2.2 Fluxo Real-time

- Streaming de dados
- Processamento em tempo real
- Análise contínua
- Alertas e notificações

1.11.2.3 Fluxo Híbrido

- Combinação de batch e real-time
- Processamento lambda
- Análise preditiva
- Detecção de anomalias

1.11.3 Gestão e Controle do Fluxo

A gestão eficiente do fluxo de dados é crucial para o sucesso da arquitetura ([GADE, 2022](#)):

1. Orquestração

- Agendamento de jobs
- Gerenciamento de dependências
- Controle de concorrência
- Recuperação de falhas

2. Monitoramento

- Métricas de performance

- Logs de execução
- Rastreamento de dados
- Alertas de anomalias

3. Governança

- Políticas de acesso
- Compliance
- Qualidade dos dados
- Lineage de dados

1.11.4 Integração e Interoperabilidade

A integração eficiente é fundamental para o sucesso do Data Fabric ([BARIK, 2022](#)):

- **Conectividade**
 - APIs padronizadas
 - Protocolos de comunicação
 - Adaptadores de fonte de dados
- **Transformação**
 - Mapeamento de dados
 - Conversão de formatos
 - Normalização de esquemas
- **Sincronização**
 - Consistência de dados
 - Replicação
 - Resolução de conflitos

1.11.5 Desafios e Considerações

A implementação do fluxo de dados em Data Fabric apresenta diversos desafios ([ADDAGADA, 2022](#)):

1. Técnicos

- Complexidade da infraestrutura

- Latência em ambientes distribuídos
- Escalabilidade

2. Operacionais

- Manutenção contínua
- Gerenciamento de recursos
- Resolução de problemas

3. Organizacionais

- Adaptação cultural
- Capacitação de equipes
- Gestão de mudanças

1.12 Ingestão de Dados e Preprocessamento de Imagens

A ingestão de dados e o preprocessamento de imagens são etapas cruciais em sistemas de análise de imagens médicas, especialmente no contexto do diagnóstico de câncer de pele. Estas etapas estabelecem a base para análises posteriores e influenciam diretamente a qualidade dos resultados obtidos ([GARCIA; RODRIGUEZ, 2023](#)).

1.12.1 Ingestão de Dados

O processo de ingestão de dados envolve a coleta e integração de diferentes tipos de dados médicos ([KUMAR; SINGH, 2023a](#)):

1.12.1.1 Fontes de Dados

- **Imagens Dermatoscópicas**
 - Fotografias clínicas de alta resolução
 - Imagens microscópicas digitalizadas
 - Imagens termográficas
- **Dados Clínicos Associados**
 - Histórico médico do paciente
 - Diagnósticos anteriores
 - Metadados das imagens

1.12.2 Preprocessamento de Imagens

O preprocessamento é fundamental para garantir a qualidade e padronização das imagens (SMITH; BROWN, 2023b):

1. Normalização de Imagens

- Ajuste de contraste
- Correção de brilho
- Padronização de tamanho
- Normalização de cores

2. Técnicas de Aprimoramento

- Redução de ruído
- Realce de bordas
- Correção de iluminação
- Filtros de suavização

3. Segmentação

- Identificação da região de interesse
- Separação lesão/pele saudável
- Remoção de artefatos

1.12.3 Pipeline de Processamento

O pipeline de processamento segue uma sequência estruturada de operações (WANG; CHEN, 2023):




Figura 2 – Pipeline de Processamento de Imagens Dermatológicas

1.12.3.1 Etapas do Pipeline

1. Validação Inicial

- Verificação de formato

- Controle de qualidade
- Validação de metadados

2. Preprocessamento Básico

- Redimensionamento
- Normalização
- Conversão de formato

3. Preprocessamento Avançado

- Segmentação
- Extração de características
- Augmentação de dados

1.12.4 Técnicas de Augmentação de Dados

A augmentação de dados é essencial para melhorar o treinamento de modelos ([ZHANG; LI, 2023](#)):

- **Transformações Geométricas**
 - Rotação
 - Reflexão
 - Escala
 - Translação
- **Transformações de Intensidade**
 - Ajuste de contraste
 - Mudança de brilho
 - Ruído gaussiano
 - Alteração de saturação

1.12.5 Controle de Qualidade

O controle de qualidade é fundamental durante todo o processo ([CHEN; WANG, 2023](#)):

1. Métricas de Qualidade

- Resolução da imagem
- Relação sinal-ruído
- Nitidez
- Contraste

2. Validação

- Verificação automática
- Revisão manual
- Testes de consistência

1.13 MinIO Object Storage

O MinIO é uma solução de armazenamento em objetos projetada para alta performance, escalabilidade e segurança. Licenciado como software open source, ele é compatível com a API do Amazon S3 e é amplamente utilizado para implementar plataformas de Armazenamento como Serviço (STaaS). A crescente demanda por aplicações como Big Data, IoT e Inteligência Artificial impulsiona a necessidade de soluções de armazenamento escaláveis e econômicas, área em que o MinIO se destaca ([BUILD... , 2019](#)).

1.13.1 Arquitetura e Benefícios

O MinIO adota uma abordagem simplificada para fornecer um sistema de armazenamento eficiente, robusto e de alta disponibilidade. Sua arquitetura em camadas é construída para suportar desde pequenas implementações até clusters globais federados. Entre suas principais características estão ([BUILD... , 2019](#)):

- Desempenho: Utilizando hardware otimizado, como processadores Intel Xeon e unidades SSD NVMe, o MinIO entrega altas taxas de transferência de dados, permitindo atender às demandas de aplicações nativas em nuvem com baixa latência e alta taxa de transferência.
- Escalabilidade Linear: Clusters do MinIO podem ser ampliados de forma linear, adicionando novos nós sem perda de desempenho, o que é essencial para cenários de armazenamento em larga escala.
- Alta Disponibilidade e Tolerância a Falhas: Com código de apagamento e verificações de proteção contra bitrot, o sistema é projetado para suportar falhas de hardware sem interrupção dos serviços.

- **Segurança:** Oferece criptografia por objeto com chaves únicas, além de suporte a gerenciamento externo de chaves e modos WORM (Write Once, Read Many).
- **Simplicidade Operacional:** O design minimalista do MinIO facilita a instalação, configuração e manutenção, reduzindo a necessidade de administração contínua.
- **Compatibilidade com Kubernetes:** A integração com orquestradores de containers permite a gestão eficiente de recursos, consolidando o MinIO como uma solução nativa para ambientes de nuvem.

1.13.2 Relevância no Cenário Atual de Armazenamento em Nuvem

O MinIO Object Storage reflete a evolução do armazenamento de dados, alinhando-se às necessidades modernas de computação em nuvem, escalabilidade e gestão eficiente de recursos. A literatura enfatiza que soluções como o MinIO não apenas preenchem lacunas tecnológicas, mas também democratizam o acesso ao armazenamento avançado, oferecendo uma alternativa competitiva às grandes provedoras de serviços em nuvem. Seu papel no ecossistema de armazenamento é crucial para suportar o crescimento exponencial de dados, previsto para ultrapassar 163 Zettabytes até 2025 ([BUILD... , 2019](#)).

1.14 Delta Lake

Delta Lake é uma camada de armazenamento de código aberto que combina as melhores características dos data warehouses e data lakes, formando a base para a arquitetura Lakehouse. Criado para solucionar problemas de confiabilidade e escalabilidade de dados, o Delta Lake suporta transações ACID, manipulação escalável de metadados e a unificação de processamento de dados em lote e streaming. Ele é amplamente utilizado em ambientes de big data e inteligência artificial devido à sua capacidade de gerenciar grandes volumes de dados com consistência e performance ([LEE et al., 2024](#)).

1.14.1 Arquitetura e Benefícios

O Delta Lake foi concebido para superar limitações de arquiteturas tradicionais de data lakes, que muitas vezes careciam de garantias transacionais e governança de dados. A arquitetura Lakehouse, da qual o Delta Lake faz parte, une a escalabilidade e flexibilidade dos data lakes com a governança e otimização de performance dos data warehouses. Entre suas principais características estão ([LEE et al., 2024](#)):

- **Transações ACID:** Garantem integridade de dados em operações concorrentes.
- **Time Travel:** Permite consultar versões anteriores dos dados para auditorias ou recuperação.

- Unificação de Processamento: Suporte simultâneo a cargas de trabalho em lote e streaming.
- Evolução e Imposição de Esquemas: Garante consistência estrutural nos dados.
- Fonte Única de Verdade: Mantém um log transacional que organiza todas as alterações de dados.

1.14.2 Relevância no Cenário Atual de Big Data

No cenário atual, caracterizado pela explosão de dados e pela crescente demanda por análise em tempo real, o Delta Lake desempenha um papel central ao permitir que organizações adotem arquiteturas de dados modernas, como o Lakehouse [3](#). Essa abordagem resolve limitações de sistemas tradicionais, que frequentemente lidam com silos de dados, altos custos de manutenção e falta de flexibilidade para suportar aplicações avançadas como inteligência artificial e aprendizado de máquina.

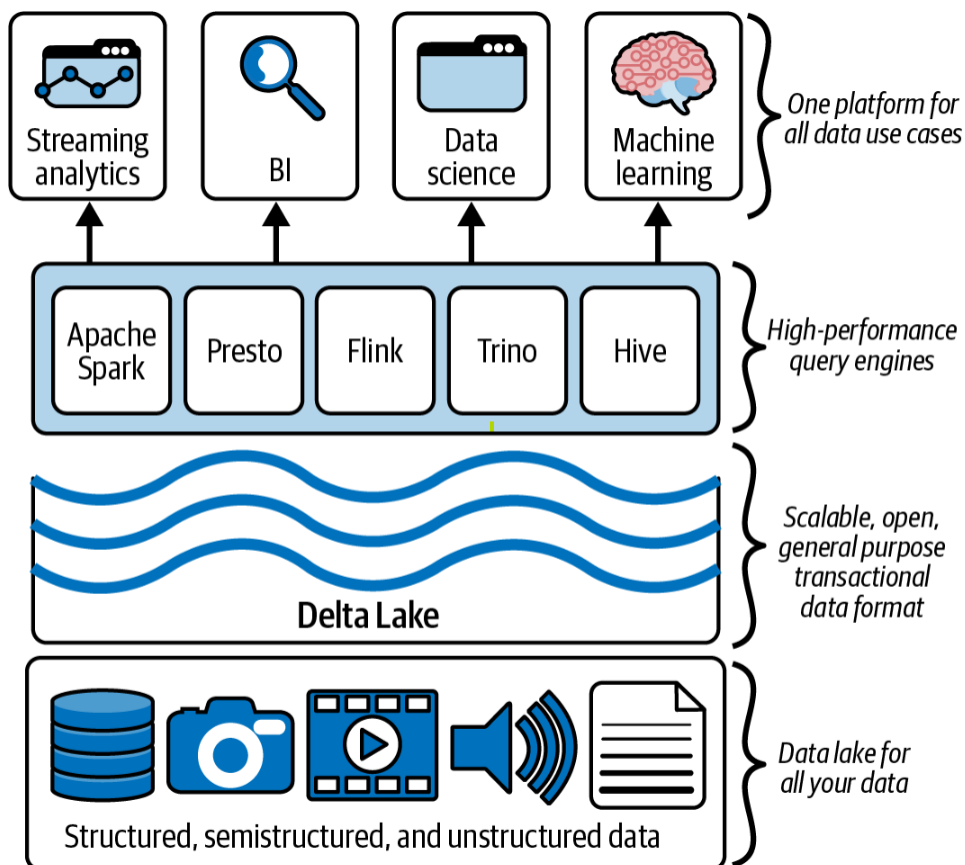


Figura 3 – Delta Lake: Formato transacional escalável e de uso geral para Lakehouse. (LEE et al., 2024)

2 Related Works

2.1 In Search of Big Medical Data Integration Solutions - A Comprehensive Survey

A integração de dados médicos, especialmente em domínios como a oncologia, tem sido foco de extensa pesquisa devido ao crescimento exponencial de dados heterogêneos, incluindo imagens médicas, dados genômicos e registros de saúde eletrônicos (EHRs). A literatura destaca múltiplas abordagens para enfrentar os desafios de integração e análise de dados no setor de saúde. (DHAYNE et al., 2019)

Dhayne et al. (DHAYNE et al., 2019) revisam tecnologias e ferramentas voltadas para a integração de dados médicos, identificando desafios relacionados à heterogeneidade de fontes e complexidade semântica dos dados. Técnicas como data warehouses modernos, data lakes e ferramentas baseadas em Hadoop têm sido propostas para consolidar e gerenciar grandes volumes de dados médicos estruturados e não estruturados. Por exemplo, o uso de arquiteturas baseadas em data lakes demonstrou potencial para integrar dados diversos, como imagens de ressonância magnética e dados de genômica, simplificando o armazenamento e o processamento.

Além disso, soluções baseadas em web semântica e aprendizado de máquina têm se mostrado promissoras. Tecnologias como o Linked Open Data (LOD) e ontologias médicas (ex.: SNOMED CT e UMLS) foram aplicadas para melhorar a interoperabilidade e a análise semântica de dados complexos. Por outro lado, modelos de aprendizado profundo (deep learning) têm sido amplamente empregados para análise de imagens médicas, promovendo a detecção precoce e a personalização de tratamentos em oncologia. (DHAYNE et al., 2019)

Projetos recentes, como o iManageCancer, demonstram a aplicação de data warehouses semânticos para integrar dados estruturados e não estruturados, facilitando análises avançadas e previsões em saúde pública. Iniciativas semelhantes têm usado frameworks como Apache Hive e Hadoop para criar plataformas escaláveis de integração e processamento de dados, destacando-se em domínios como prevenção de obesidade e previsão de doenças crônicas. (DHAYNE et al., 2019)

Apesar do progresso significativo, a literatura aponta lacunas em relação à integração de dados médicos baseados em imagens, como a ausência de abordagens padronizadas para integrar metadados e dados visuais em um framework unificado. Este trabalho busca abordar essa lacuna, propondo uma arquitetura de data fabric específica para imagens de

câncer, com foco na interoperabilidade e eficiência analítica.

2.2 What Clinics Are Expecting From Data Scientists? A Review on Data Oriented Studies Through Qualitative and Quantitative Approaches

Recentemente, a exploração de como a análise de dados pode ser integrada a ambientes clínicos para melhorar a tomada de decisão médica e o manejo de doenças. A ideia de "Connected Health"(CH), que conecta pacientes, clínicos e pesquisadores, vem sendo amplamente discutida como um paradigma para transformar dados médicos em informações úteis e acionáveis. Em particular, a "Translational Medicine"(TM) atua como uma ponte entre cientistas de dados e profissionais de saúde, visando à análise preditiva de dados como prontuários eletrônicos e resultados laboratoriais para identificar riscos e formular diagnósticos mais precisos. (XU et al., 2019)

No entanto, enquanto a análise quantitativa é dominante na pesquisa de saúde, revisões apontam que abordagens qualitativas têm demonstrado maior aplicabilidade em áreas como a interpretação de narrativas de pacientes e a análise de padrões complexos em dados de saúde. Estudos demonstraram que técnicas qualitativas, combinadas com análise quantitativa, permitem insights mais abrangentes, especialmente no contexto de doenças como câncer, onde múltiplas fontes de dados, como imagens médicas e genômicas, precisam ser integradas para melhores resultados clínicos. (XU et al., 2019)

Ainda assim, desafios éticos e técnicos relacionados à interoperabilidade de dados e à preservação de privacidade continuam sendo barreiras significativas para o uso pleno de sistemas como registros eletrônicos de saúde (EHR). Modelos de sucesso incluem a adoção de padrões de interoperabilidade como o HL7 e iniciativas como o programa "Big Data to Knowledge"(BD2K), que promove a utilização de big data para extrair informações significativas de dados biomédicos.

A integração de técnicas qualitativas e quantitativas na análise de dados de imagens médicas em câncer, alinhada a estratégias de interoperabilidade e padronização, representa uma oportunidade crucial para melhorar a detecção precoce e os tratamentos personalizados. Assim, o desenvolvimento de arquiteturas de dados robustas e interdisciplinares permanece um campo de interesse crescente, com potencial para avanços significativos em sistemas de saúde conectados. (XU et al., 2019)

Referências

- ADDAGADA, T. Best practices for managing a data fabric. *DATAVERSITY*, 2022. Citado na página 59.
- AKHTAR, R. Decentralized data mesh architectures: Benefits and challenges. *Journal of Data Science*, p. 123–145, 2021. Citado 2 vezes nas páginas 44 e 45.
- ALHASSAN, I.; SAMMON, D.; DALY, M. Data governance activities: An analysis of the literature. *Journal of Decision Systems*, p. 64–75, 2016. Citado na página 32.
- ARUNDEL, J.; DOMINGUS, J. *Cloud Native DevOps with Kubernetes*. [S.l.]: O'Reilly Media, 2021. Citado na página 50.
- BARIK, R. *Data Fabric Primer*. [S.l.], 2022. Disponível em: <<https://www.globallogic.com/in/wp-content/uploads/sites/21/2023/12/Paper-Data-Fabric-primer.pdf>>. Citado 5 vezes nas páginas 39, 40, 41, 42 e 58.
- BENFELDT, O.; PERSSON, J. S.; MADSEN, S. Data governance as a collective action problem. *Information Systems Frontiers*, p. 299–313, 2020. Citado na página 34.
- BLOHM, I. et al. Data products, data mesh, and data fabric: New paradigm(s) for data and analytics? *Business & Information Systems Engineering*, p. 643–652, 2024. Citado 2 vezes nas páginas 40 e 57.
- BROWN, S.; JOHNSON, M. Securing fastapi applications: Best practices and patterns. *Security Engineering Review*, v. 8, p. 45–67, 2023. Citado na página 52.
- BUILD a High-Performance Object Storage-as-a-Service Platform with MinIO. [S.l.], 2019. Acessado em: 5 jan. 2025. Disponível em: <<https://min.io/resources/docs/CPG-MinIO-reference-architecture.pdf>>. Citado 2 vezes nas páginas 62 e 63.
- BURNS, B.; BEDA, J.; HIGHTOWER, K. *Kubernetes: Up and Running: Dive into the Future of Infrastructure*. [S.l.]: O'Reilly Media, 2019. Citado na página 48.
- CHANG, J.; SHARMA, R. Apache airflow: Platform for programmatically authoring, scheduling and monitoring workflows. *Journal of Big Data Processing*, p. 45–67, 2021. Citado na página 46.
- CHEN, D.; MARTINEZ, A. Challenges in implementing ai-powered dermatological diagnosis systems. *Journal of Healthcare Engineering*, v. 8, p. 145–167, 2023. Citado na página 55.
- CHEN, D.; WANG, L. Quality control in medical image processing pipelines. *Biomedical Engineering Review*, v. 10, p. 112–134, 2023. Citado na página 62.
- DEHGHANI, Z. *Data Mesh: Delivering Data-Driven Value at Scale*. [S.l.: s.n.], 2020. Citado 2 vezes nas páginas 44 e 45.
- DHAYNE, H. et al. In search of big medical data integration solutions - a comprehensive survey. *IEEE Access*, 2019. Citado na página 67.

- DOAN, A. et al. Information extraction challenges in managing unstructured data. *SIGMOD Record*, p. 14–20, 2008. Citado na página 34.
- ESTEVA, A.; TOPOL, E. Deep learning-enabled medical computer vision. *Nature Digital Medicine*, v. 5, p. 1–9, 2022. Citado na página 53.
- FANG, T. *Data Lakes: Foundations and Innovations*. [S.l.: s.n.], 2021. Citado na página 43.
- FOUNDATION, A. S. *Best Practices for Apache Airflow Implementation*. [S.l.], 2023. Disponível em: <<https://airflow.apache.org/docs/>>. Citado na página 48.
- GADE, K. R. Data analytics: Data fabric architecture and its benefits for data management. *MZ Computing Journal*, 2022. Citado 3 vezes nas páginas 39, 42 e 57.
- GARCIA, M.; LUMBRERAS, J. *Data Pipelines with Apache Airflow*. [S.l.]: Manning Publications, 2021. Citado na página 46.
- GARCIA, M.; RODRIGUEZ, J. Medical image processing: From acquisition to analysis. *Journal of Medical Imaging*, v. 12, p. 145–167, 2023. Citado na página 59.
- Gartner. *What is Data Fabric? Uses, Definition & Trends*. 2024. Accessed: 2024-12-19. Disponível em: <<https://www.gartner.com/en/data-analytics/topics/data-fabric>>. Citado na página 39.
- GONZALEZ, M. Scalable systems for big data management. *Journal of Big Data*, 2019. Citado na página 43.
- HAUG, A.; ZACHARIASSEN, F.; LIEMPD, D. van. The costs of poor data quality. *Journal of Industrial Engineering and Management*, p. 168–193, 2011. Citado na página 31.
- HECHLER, E.; WEIHRAUCH, M.; WU, Y. C. *Data Fabric and Data Mesh Approaches with AI: A Guide to AI-based Data Cataloging, Governance, Integration, Orchestration, and Consumption*. [S.l.]: Apress, 2023. 38–42 p. Citado 2 vezes nas páginas 41 e 56.
- HIGHTOWER, K.; BURNS, B.; BEDA, J. *Kubernetes: The Complete Guide*. [S.l.]: CNCF, 2019. Citado na página 49.
- JAHNKE, L.; ASHER, A.; KERALIS, S. D. *The Problem of Data*. [S.l.], 2012. Disponível em: <<https://www.clir.org/pubs/reports/pub154/>>. Citado na página 35.
- JOHNSON, P. Scaling data architectures with mesh principles. *Data Engineering Quarterly*, p. 34–50, 2021. Citado na página 45.
- KATAL, A.; WAZID, M.; GOUDAR, R. H. Big data: Issues, challenges, tools and good practices. In: *Proceedings of the Sixth International Conference on Contemporary Computing (IC3)*. [S.l.: s.n.], 2013. p. 404–409. Citado na página 32.
- KUMAR, A.; PATEL, S. *Medical Image Processing Pipelines: Design and Implementation*. [S.l.]: Springer, 2023. Citado na página 54.
- KUMAR, R.; SINGH, A. Data ingestion strategies for medical imaging systems. *Healthcare Informatics Journal*, v. 8, p. 234–256, 2023. Citado na página 59.

- KUMAR, R.; SINGH, A. Modern api development with fastapi and python. *Journal of Software Engineering*, v. 15, p. 123–145, 2023. Citado 2 vezes nas páginas 51 e 53.
- KUMAR, V.; SINGH, R. Apache airflow: A comprehensive study of workflow management. *International Journal of Data Engineering*, v. 13, p. 78–92, 2022. Citado na página 46.
- LEE, D. et al. *Delta Lake: The Definitive Guide: Modern Data Lakehouse Architectures with Data Lakes*. [S.l.]: O'Reilly Media, 2024. Citado 3 vezes nas páginas 17, 63 e 65.
- L'HEUREUX, A. et al. Machine learning with big data: Challenges and approaches. *IEEE Access*, p. 7776–7797, 2017. Citado na página 32.
- LUKSA, M. *Kubernetes in Action*. [S.l.]: Manning Publications, 2021. Citado na página 49.
- MARTINEZ, C.; THOMPSON, E. Best practices for large-scale fastapi applications. *Web Engineering Quarterly*, v. 4, p. 78–95, 2023. Citado na página 52.
- MARTINEZ, L. Federated governance in data mesh implementations. *International Journal of Data Management*, v. 15, p. 56–78, 2022. Citado na página 45.
- MOUSA, A. H.; SHIRATUDDIN, N. Data warehouse and data virtualization comparative study. In: *2015 International Conference on Developments of E-Systems Engineering (DeSE)*. [S.l.: s.n.], 2015. p. 369–372. Citado 2 vezes nas páginas 38 e 39.
- NAMBIAR, A.; MUNDRA, D. An overview of data warehouse and data lake in modern enterprise data management. *Big Data and Cognitive Computing*, p. 132, 2022. Citado na página 35.
- NUTHALAPATI, A. *Architecting data lake-houses in the cloud: Best practices and future direction*. [S.l.: s.n.], 2018. 1903 p. Citado na página 43.
- PETERSON, E.; LEE, J. *FastAPI Performance Analysis in Production Environments*. [S.l.], 2023. Citado na página 52.
- RAMÍREZ, S. Fastapi: A modern framework for building apis with python. *Python Software Foundation*, 2023. Citado na página 50.
- RAMÍREZ, S.; GONZÁLEZ, M. *Building Data-Intensive Applications with FastAPI*. [S.l.]: O'Reilly Media, 2022. Citado na página 50.
- REDMAN, T. C. The impact of poor data quality on the typical enterprise. *ACM*, p. 79–82, 1998. Citado 3 vezes nas páginas 31, 33 e 34.
- SANTOSO, L. W.; YULIA. Data warehouse with big data technology for higher education. In: *Proceedings of the 4th Information Systems International Conference (ISICO 2017)*. [S.l.: s.n.], 2017. Citado 3 vezes nas páginas 36, 37 e 38.
- SHARMA, P.; GUPTA, R. Scalable data pipeline orchestration with apache airflow. In: *Proceedings of the International Conference on Big Data Engineering*. [S.l.: s.n.], 2021. p. 234–245. Citado na página 47.
- SHARMA, V. et al. (Ed.). *Data Fabric Architectures: Web-Driven Applications*. [S.l.]: De Gruyter, 2023. Citado 2 vezes nas páginas 41 e 56.

- SMITH, J.; BROWN, R. Quality assurance in medical image processing. *Healthcare Data Management*, v. 15, p. 78–95, 2023. Citado na página 55.
- SMITH, J.; BROWN, S. *Image Preprocessing Techniques in Medical Analysis*. [S.l.]: Academic Press, 2023. Citado na página 60.
- SMITH, K. Open source tools for data mesh implementations. *Open Data Review*, p. 90–105, 2023. Citado na página 45.
- STONE, M. et al. From information mismanagement to misinformation - the dark side of information management. *The Bottom Line*, 2019. Citado na página 33.
- VAISMAN, A.; ZIMÁNYI, E. *Data Warehouse Systems: Design and Implementation*. [S.l.]: Springer, 2014. 72–80 p. (Data-Centric Systems and Applications). Citado 3 vezes nas páginas 35, 37 e 38.
- VASS, J.; STEWART, M. *Big Data Management in the Cloud Era*. [S.l.: s.n.], 2020. Citado na página 43.
- VERMA, A.; PEDROSA, L.; KORUPOLU, M. Large-scale cluster management at google with borg. *Proceedings of the European Conference on Computer Systems*, p. 18–33, 2020. Citado na página 48.
- VOLK, M. et al. Challenging big data engineering: Positioning of current and future development. In: *Proceedings of the 4th International Conference on Internet of Things, Big Data and Security (IoTBDS)*. [S.l.: s.n.], 2019. p. 351–358. Citado 2 vezes nas páginas 32 e 34.
- WANG, M.; CHEN, L. Automated skin lesion analysis using deep learning pipelines. *Journal of Medical Imaging*, v. 10, p. 234–256, 2023. Citado 2 vezes nas páginas 54 e 60.
- WILSON, J. *Data Integration Patterns with FastAPI*. [S.l.]: Apress, 2023. Citado na página 51.
- XU, L. et al. What clinics are expecting from data scientists? a review on data oriented studies through qualitative and quantitative approaches. *IEEE Access*, 2019. Citado na página 68.
- ZAGAN, E.; DANUBIANU, M. Data lake approaches: A survey. p. 189–191, 2020. Citado na página 43.
- ZHANG, J.; WANG, L.; SINGH, R. Deep learning applications in dermatological image analysis. *Medical Image Analysis*, v. 28, p. 187–203, 2021. Citado na página 53.
- ZHANG, W.; LI, X. Data augmentation techniques for medical image analysis. *Pattern Recognition in Medicine*, v. 15, p. 78–95, 2023. Citado na página 61.